
Universidad del Rosario
Escuela de Ingeniería, Ciencia y Tecnología
DEPE
VISUALIZACIÓN DE DATOS CON R
SÁBADO
11 DE MARZO
10:00 AM A 12:00 PM
En este taller se crearán gráficos descriptivos de un conjunto de datos usando la "gramática de los gráficos" y el paquete ggplot2
SALA KNUTH
MODALIDAD ACCESO REMOTO
NO SE REQUIERE EXPERIENCIA PREVIA EN PROGRAMACIÓN

Sobre el conferencista



Miguel Angel Orjuela Rocha

Ing. de Sistemas y Computación

Skills:

- Desarrollo Fullstack
- Analítica de datos
- Transferencia de conocimiento

Contacto:

miguela.orjuela@urosario.edu.co

https://www.linkedin.com/in/miguel-orjuela/

https://github.com/maorjuela73

Contenido

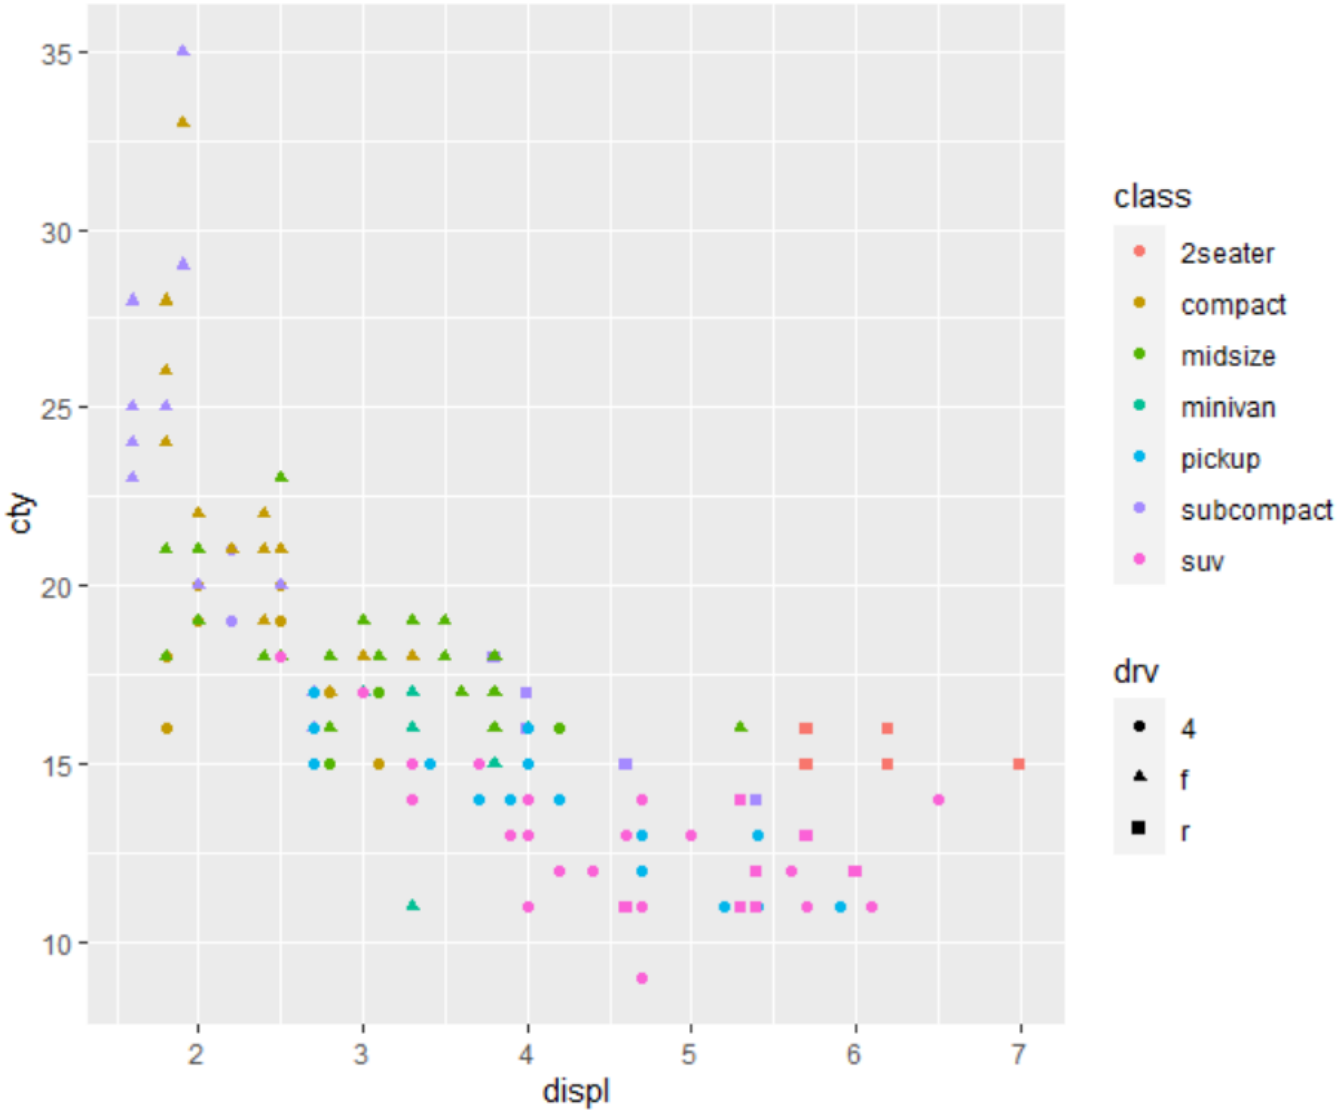


- Introducción
- Herramientas a emplear
- Gramática de los gráficos
- Primer gráfico
- Práctica con datasets sencillos
- Datos de ejemplo
- Tipos de variables
- Gráficos más importantes para describir datos

Introducción

Algunas preguntas

- ¿Qué es un gráfico?
- ¿Qué tipos de gráficos existen?
- ¿Cómo describirías este gráfico?



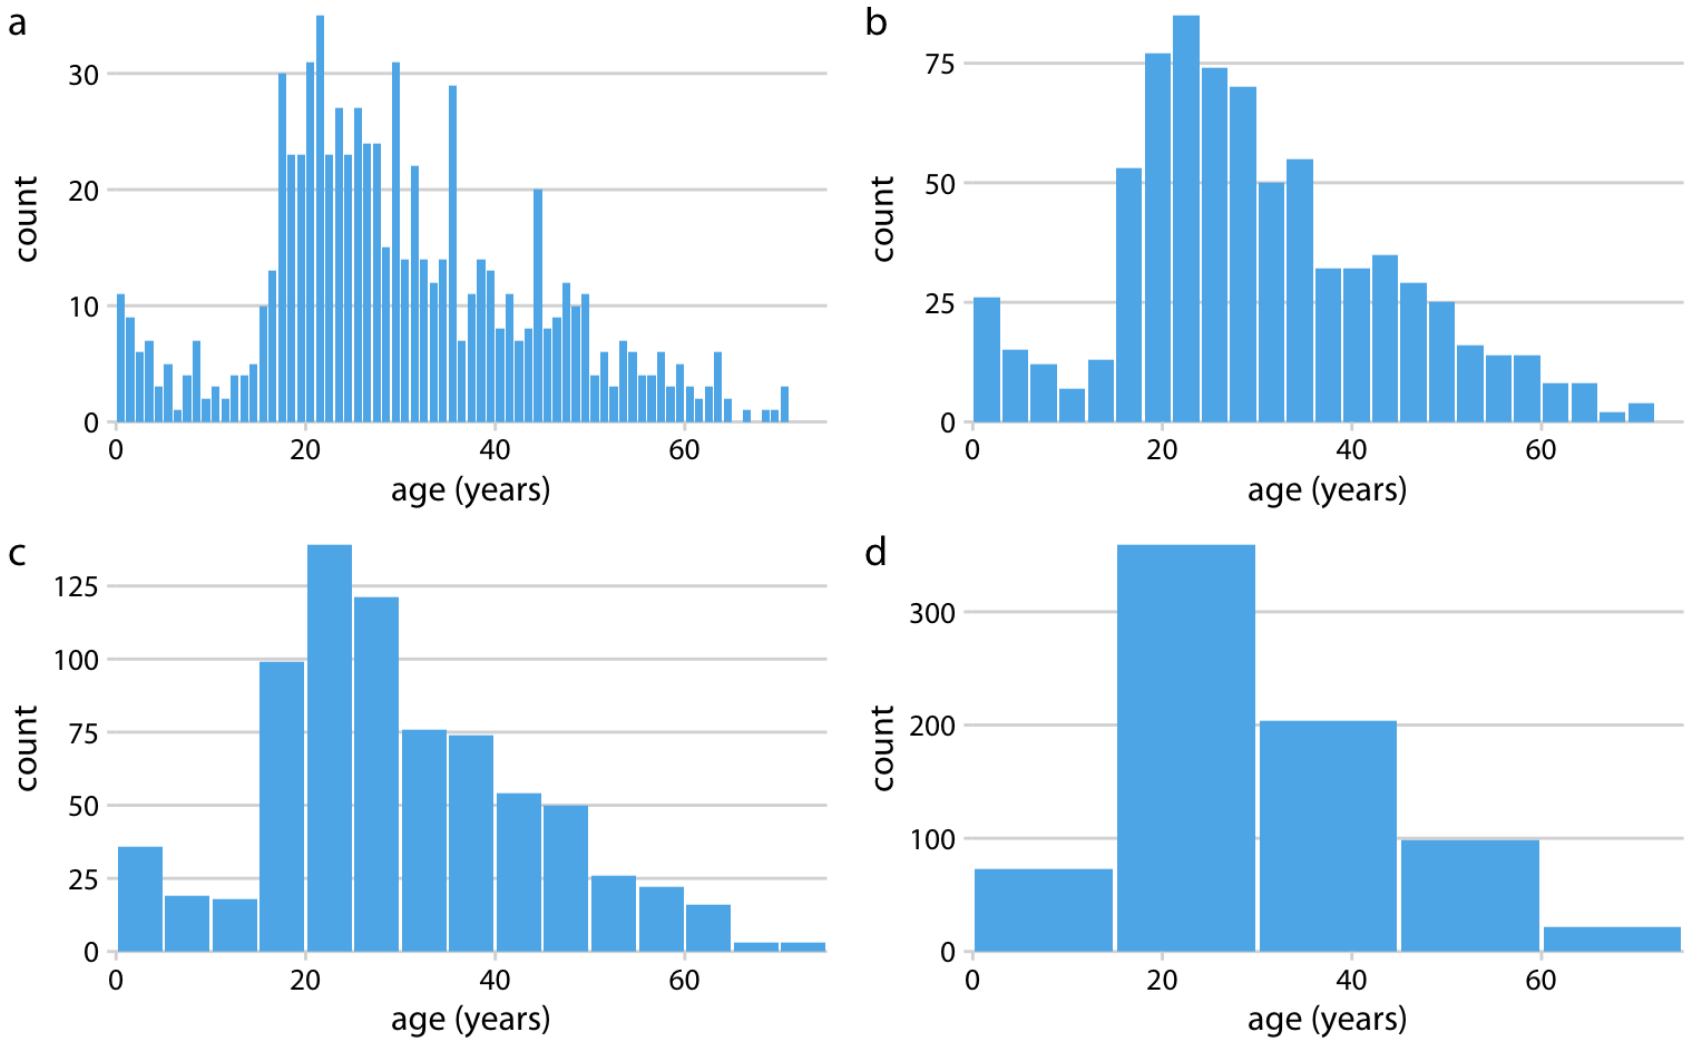
Presentación de datos de forma visual en una manera sistémica

Visualización de datos

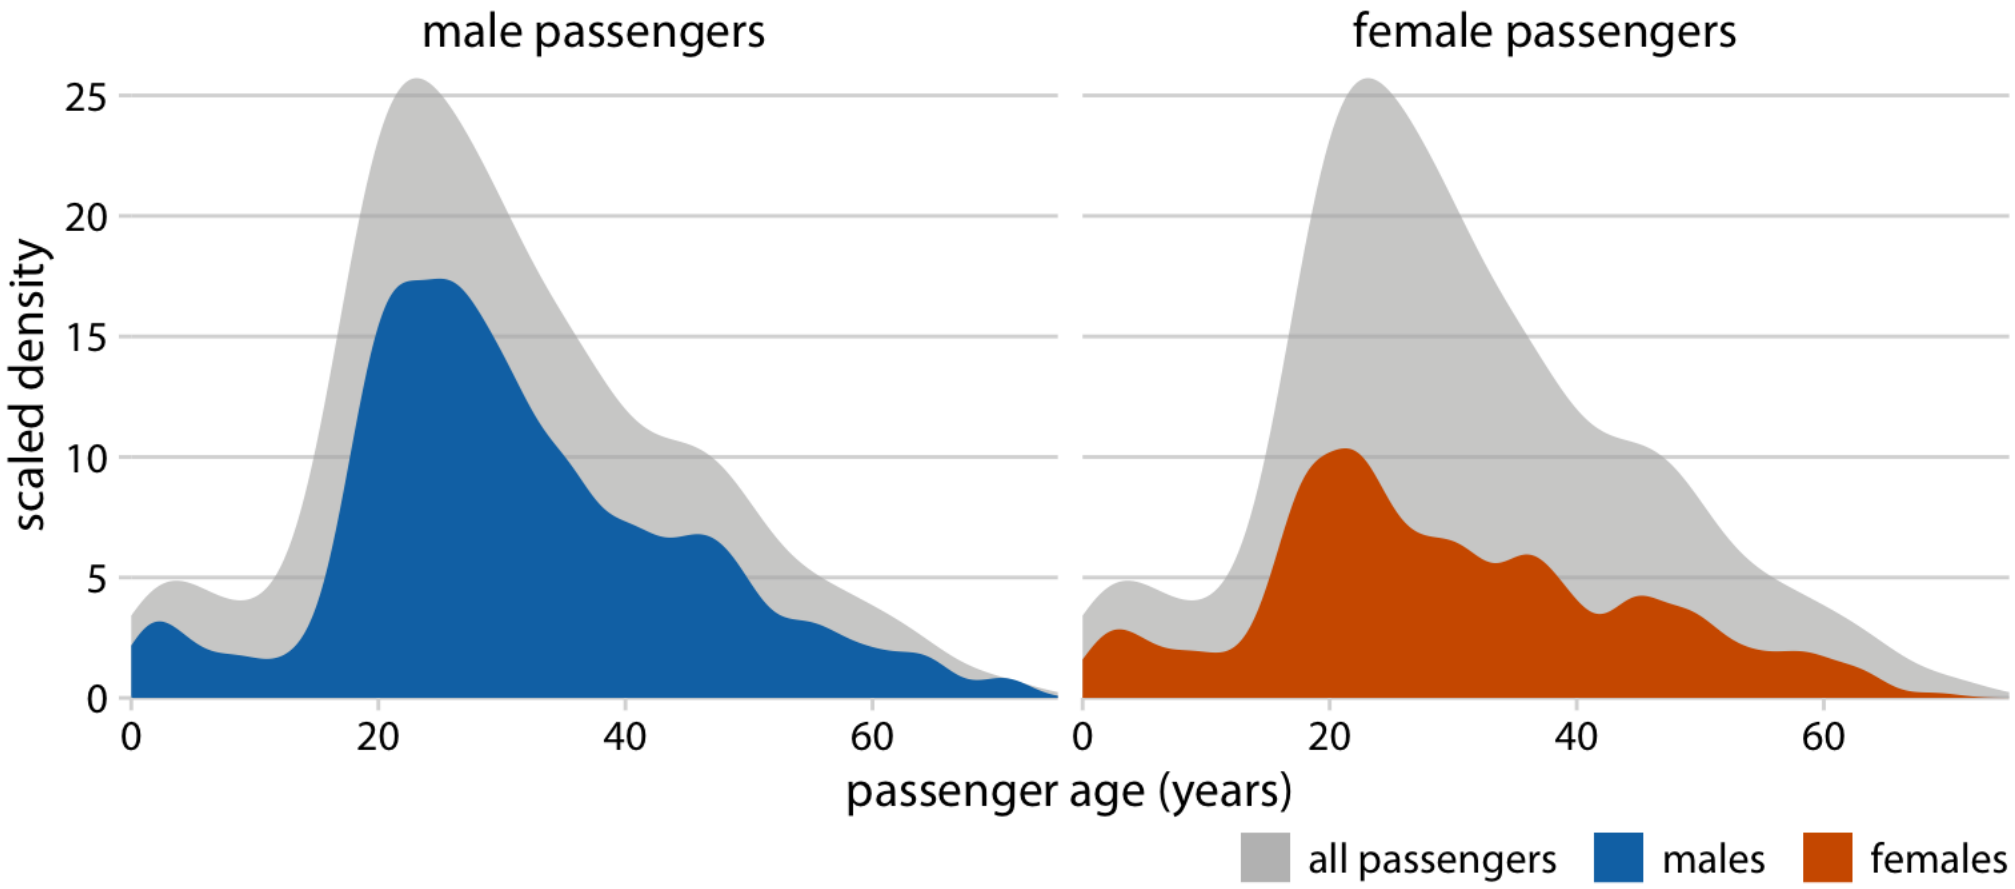
Útil para:

- Análisis Exploratorio de Datos
- Transmitir una historia a una audiencia
- Ver patrones
- Plantear nuevas preguntas

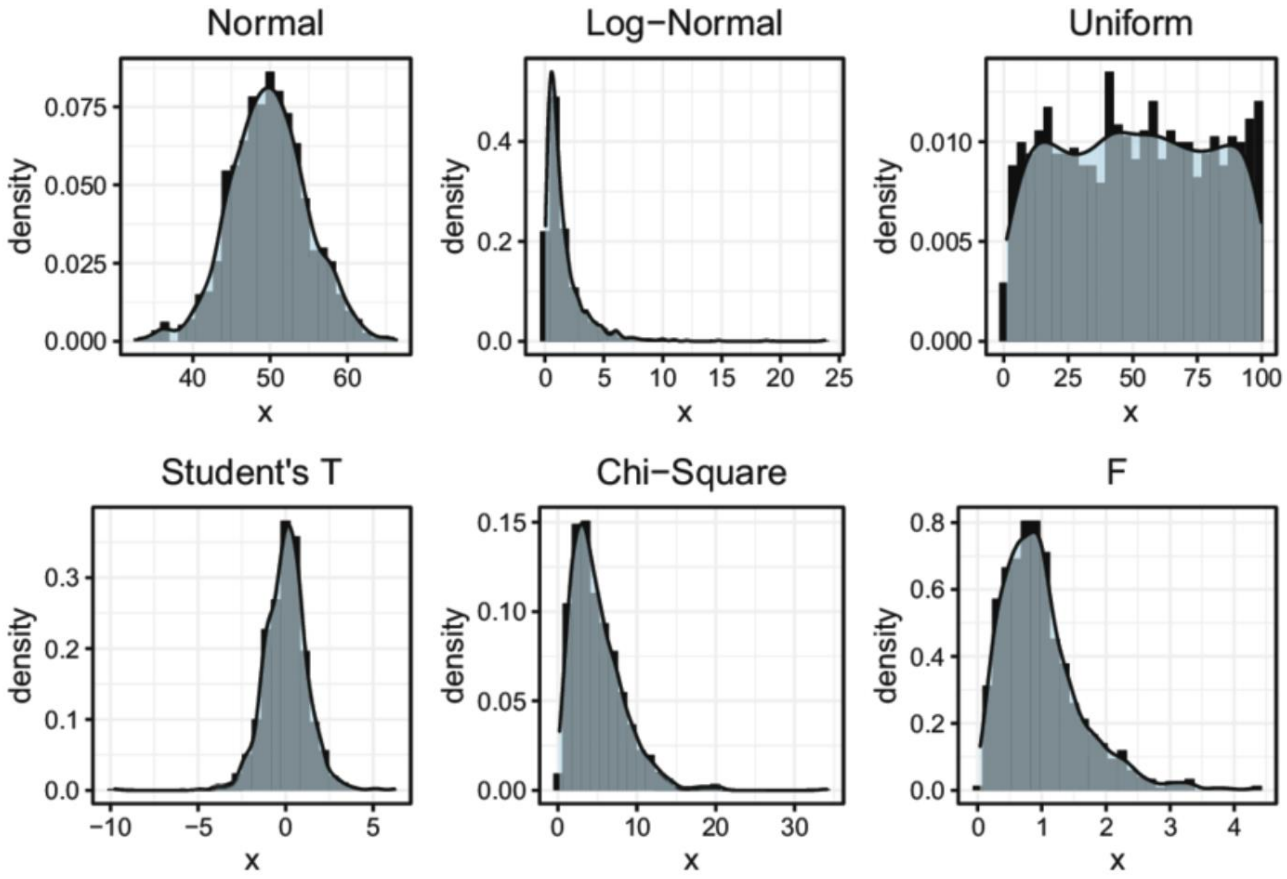
Distribución de los datos

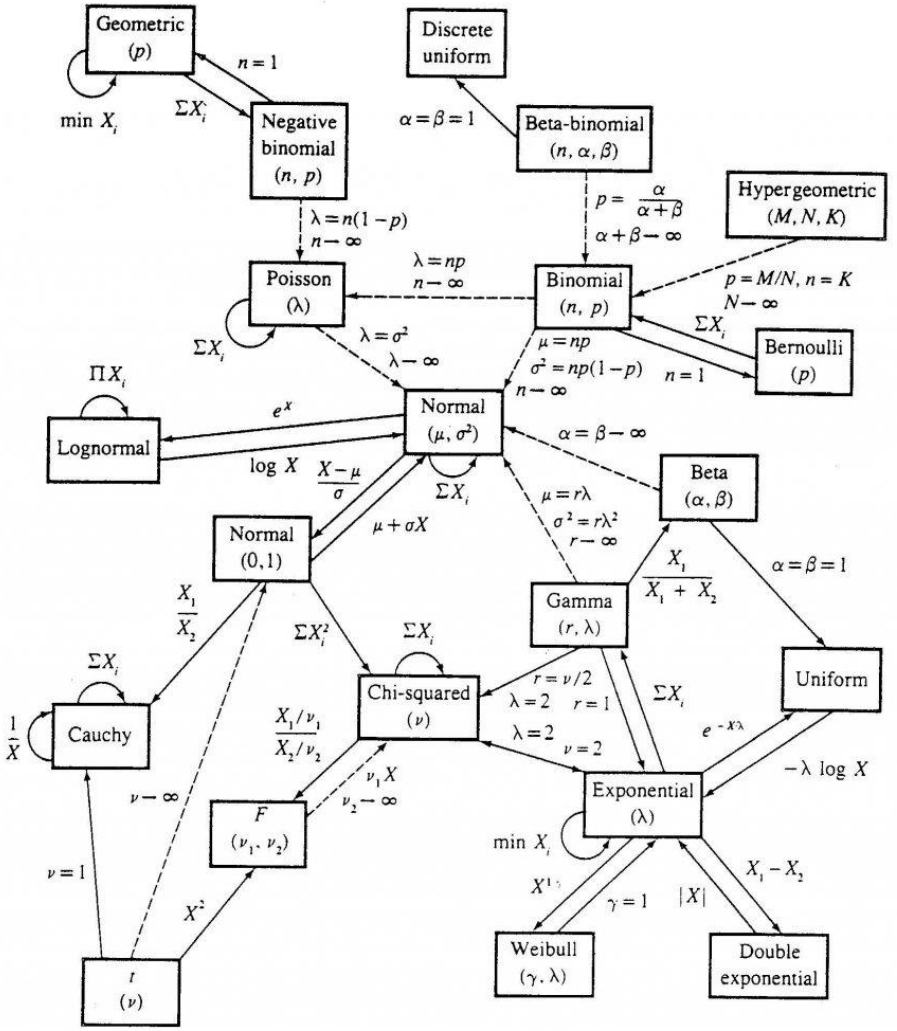


Distribución de los datos



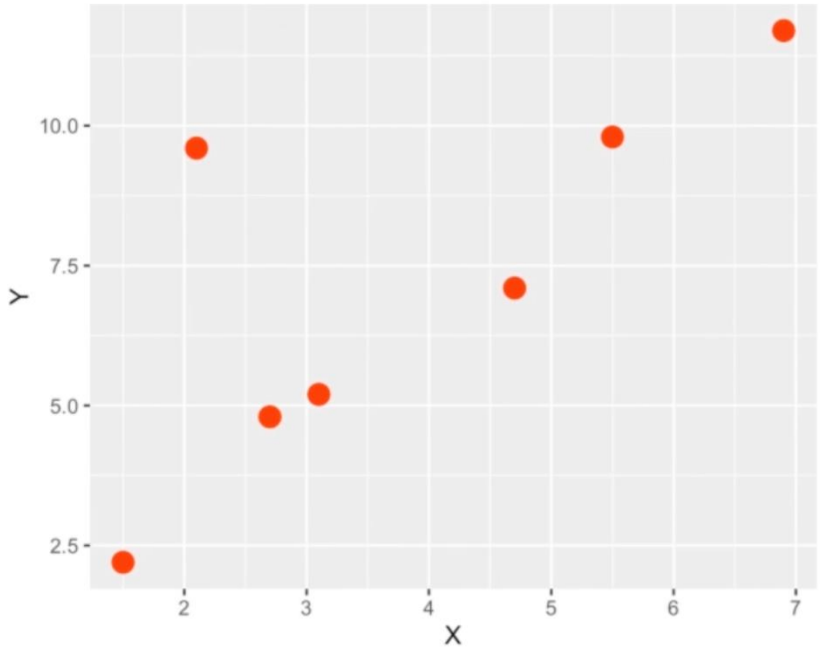
Distribución de los datos



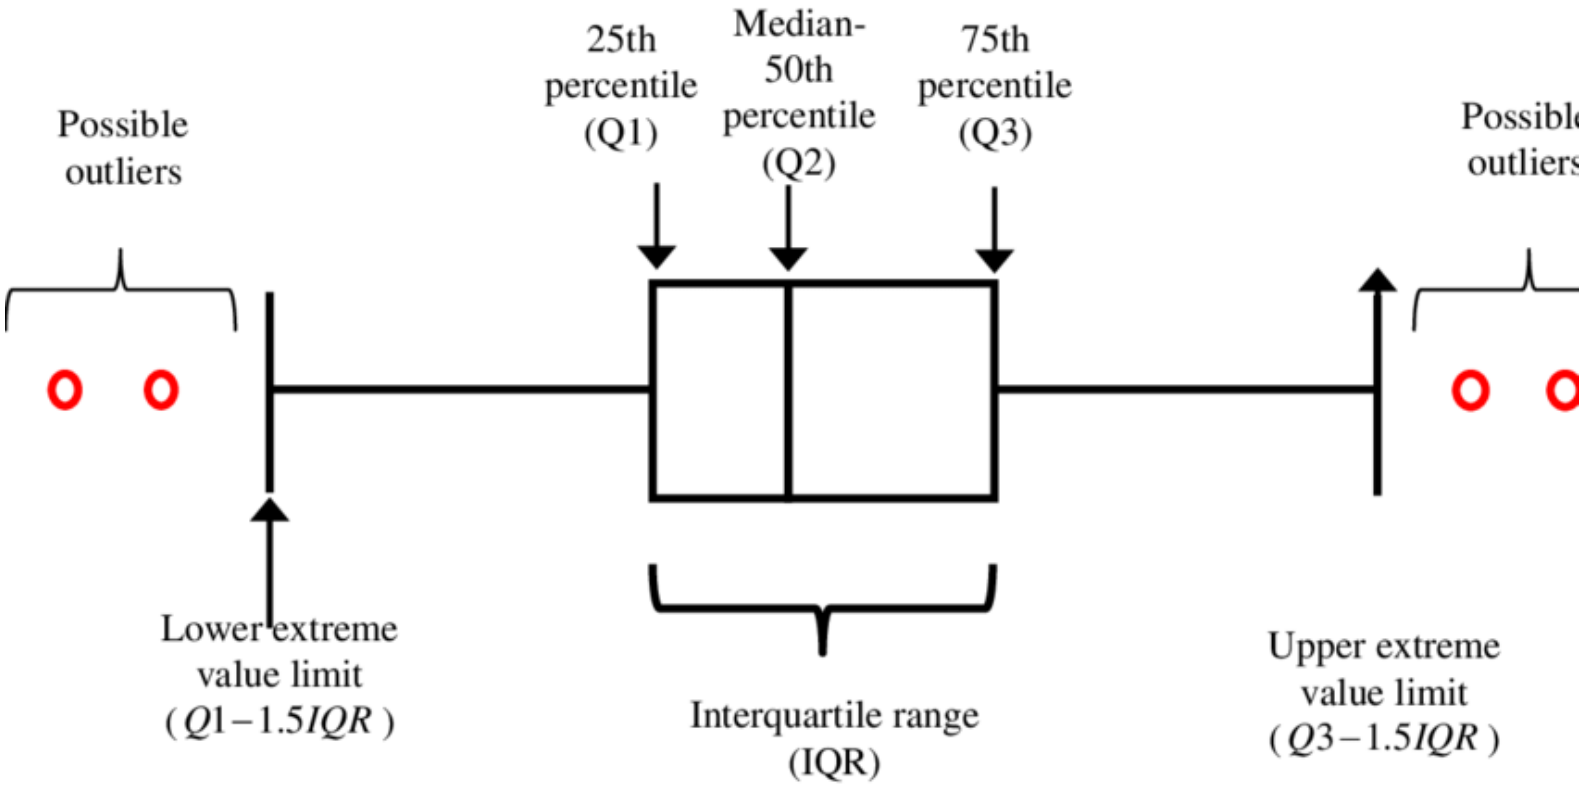


Detección de datos atípicos (outliers)

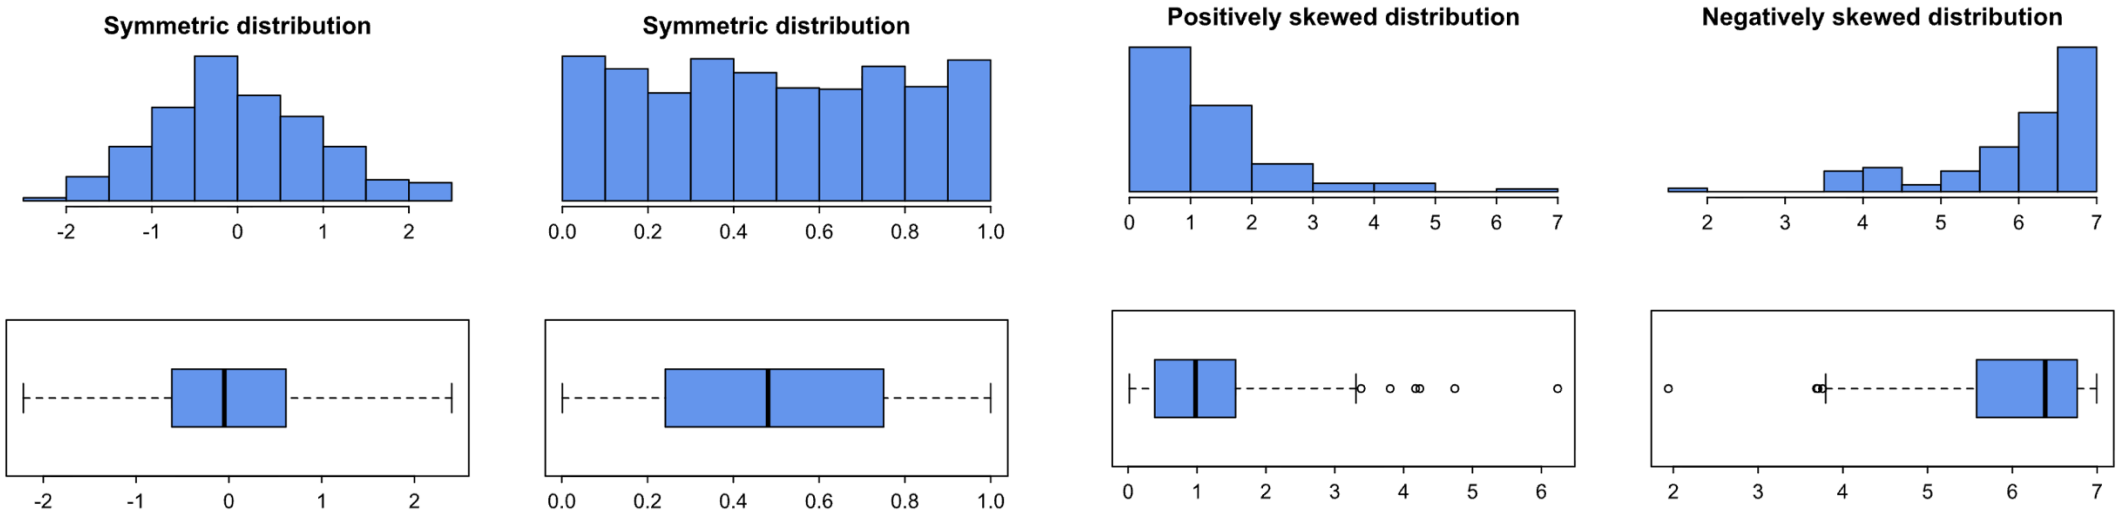
X	Y
1.5	2.2
2.1	9.6
5.5	9.8
3.1	5.2
6.9	11.7
4.7	7.1
2.7	4.8



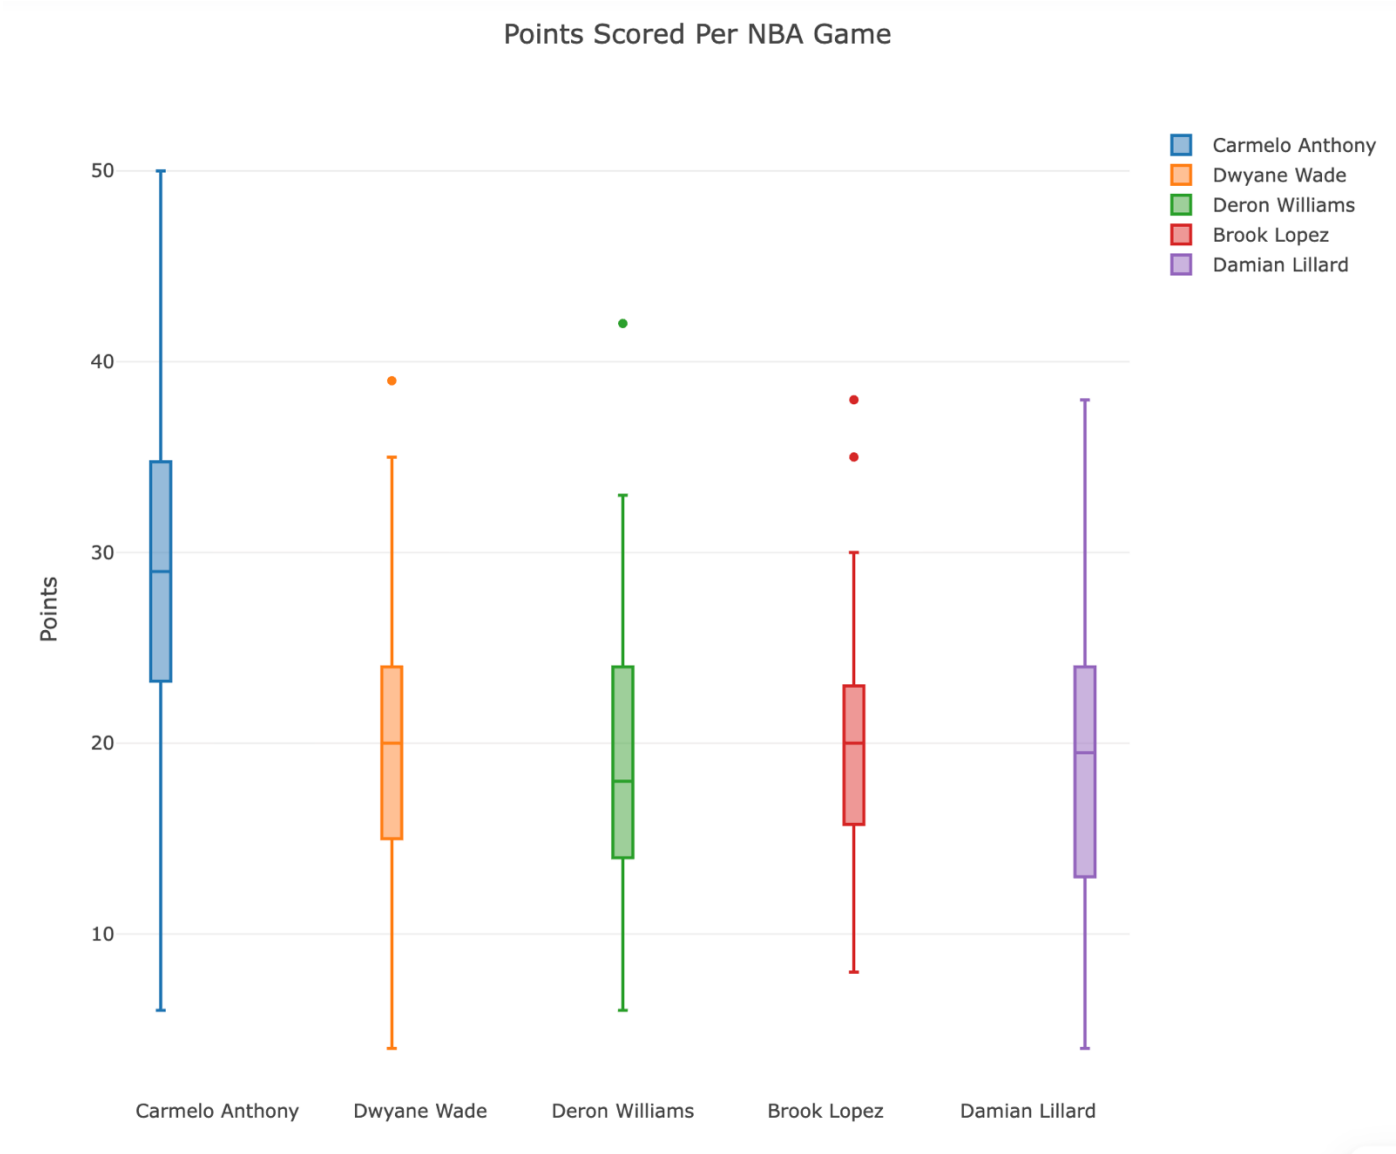
Detección de datos atípicos (outliers)



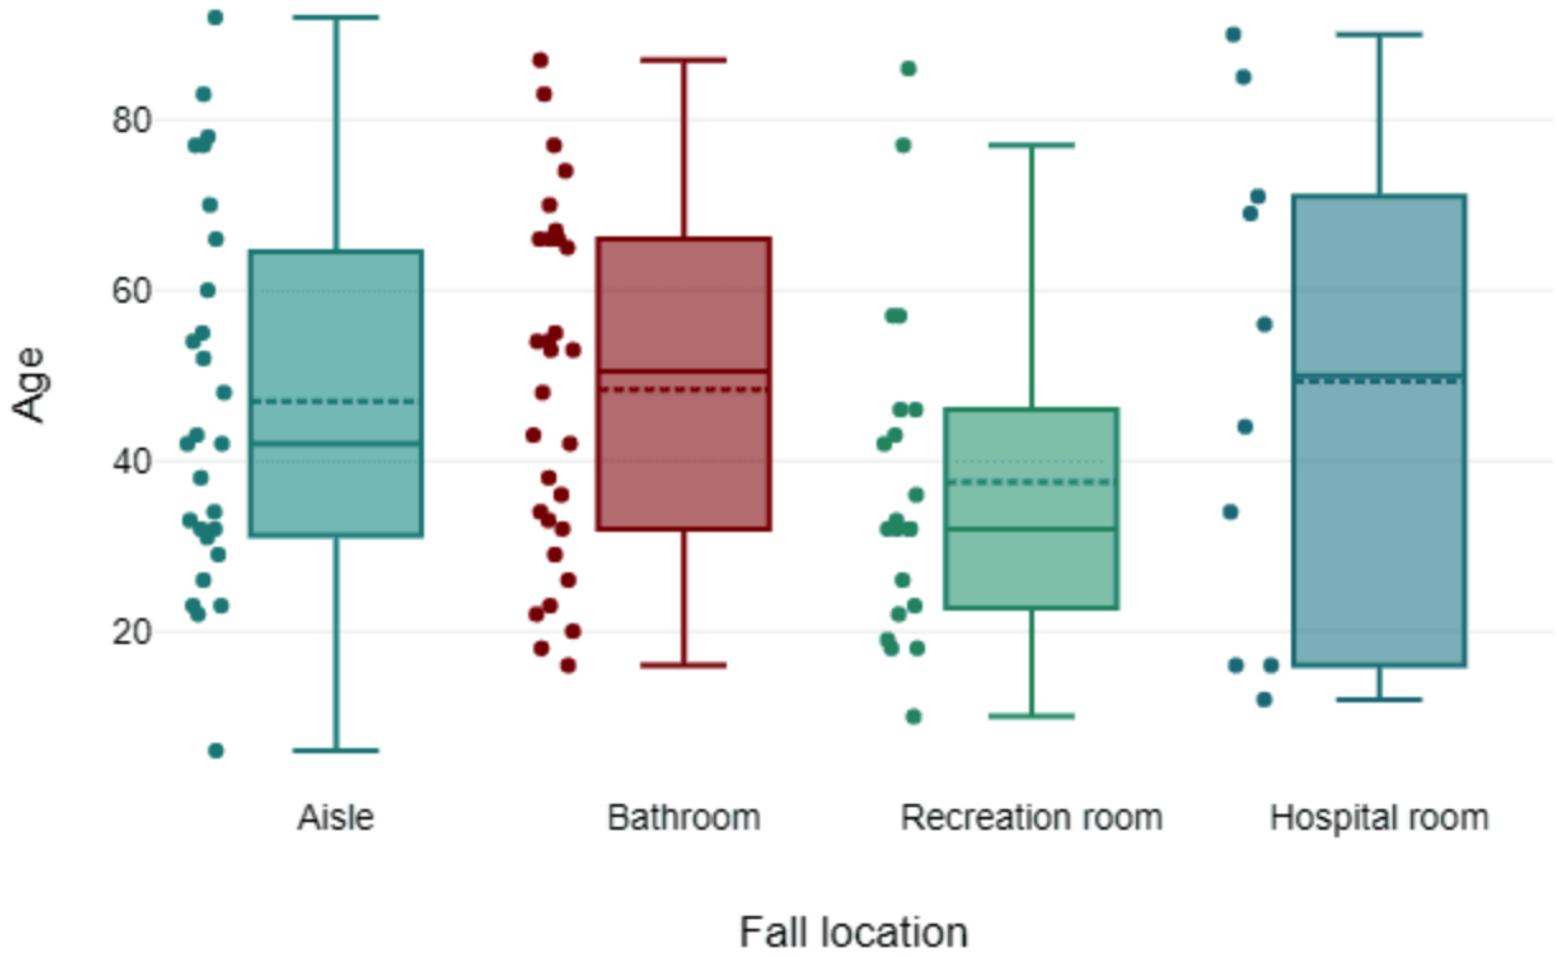
Detección de datos atípicos (outliers)



Detección de datos atípicos (outliers)



Detección de datos atípicos (outliers)



Herramientas a emplear

RStudio Cloud

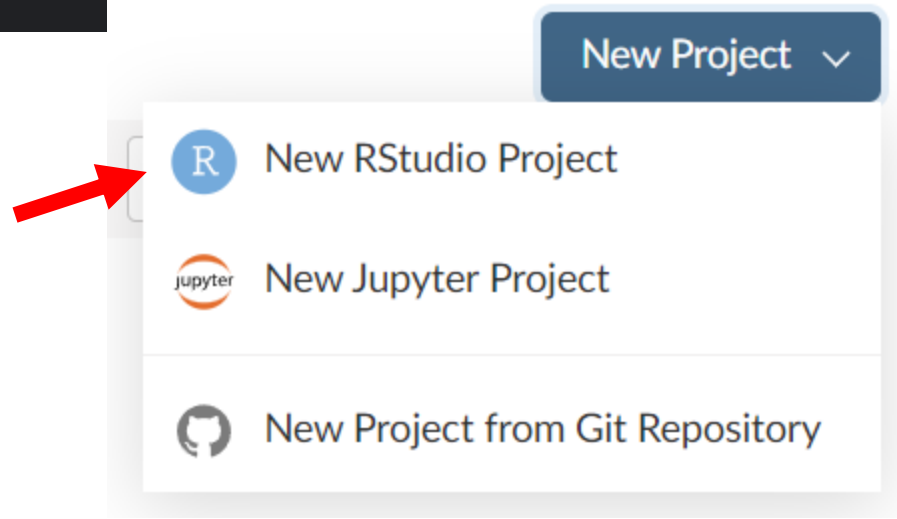
- Servicio web que permite ejecutar R en la nube (servidores de RStudio)

https://rstudio.cloud ▾ Traducir esta página

RStudio Cloud

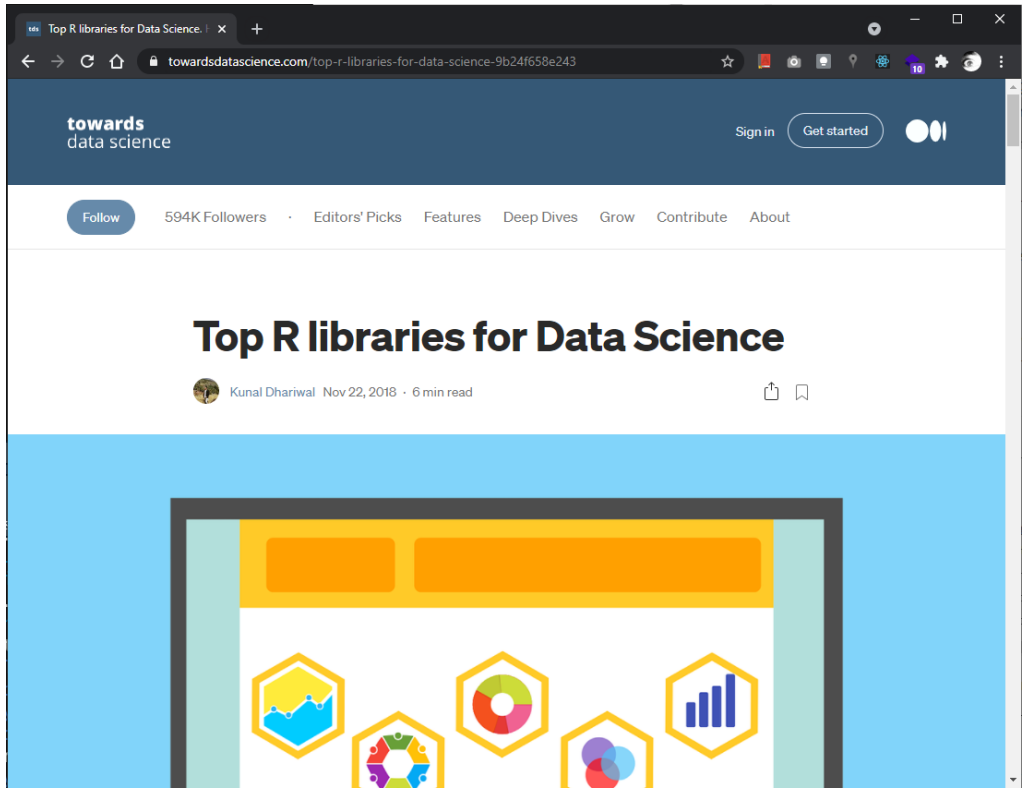
RStudio Cloud is a lightweight, cloud-based solution that allows anyone to do, share, teach and learn data science online. ... There is nothing to configure and ...

- Se inicia sesión y se crea un nuevo proyecto



Instalación de paquetes

Herramientas a emplear




```r
# Se necesitan instalar una vez
# por computador

install.packages("nombrepaquete")

# pero hay que cargarlo cada vez
# que se inicia R

library(nombredelpaquete)
```

Instalación de paquetes

Herramientas a emplear

```
# librerías importantes

library(readr)

library(tidyr)

library(dplyr)

library(ggplot2)
```



Paquete **tidyverse**

`library(tidyverse)` las incluye todas

```
> library(tidyverse)
-- Attaching packages --------------- tidyverse 1.3.1 --
v ggplot2 3.3.3     v purrr   0.3.4
v tibble  3.1.1     v dplyr   1.0.5
v tidyr   1.1.3     v stringr 1.4.0
v readr   1.4.0     v forcats 0.5.1
-- Conflicts ------------------ tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
x dplyr::lag()    masks stats::lag()
```

Gramática de los gráficos

¿Qué es la gramática de los gráficos?

- Basada en **The Grammar of Graphics** de Leland Wilkinson: un marco para describir componentes comunes a todo gráfico estadístico.

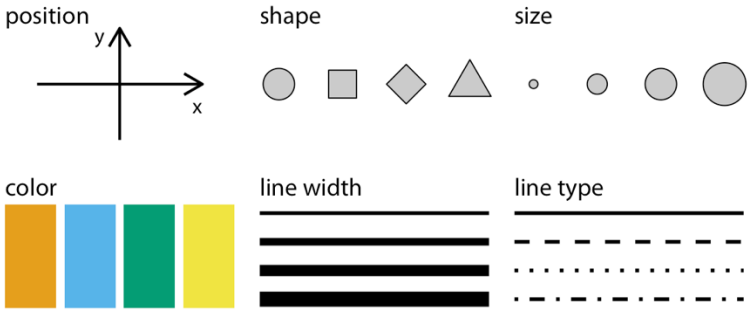
- Wickham adaptó esta idea en ggplot2, creando una gramática **por capas** (layered grammar), con estructura modular.

http://vita.had.co.nz/papers/layered-grammar.pdf

- **Ventaja**: permite construir y modificar gráficos de manera flexible, iterativa y coherente.

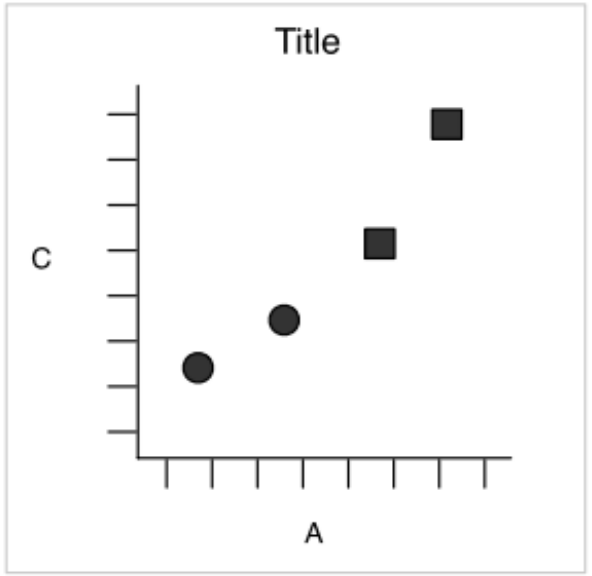
Componentes de un gráfico

- **Datos**: Dataset base
- **Mapeos estéticos** (**aes**thetic **map**ping): cómo variables se enlazan a atributos visuales (x, y, color, tamaño…)



- **Geom**: objetos gráficos (puntos, barras, líneas…)
- **Stat**: transformaciones estadísticas (frecuencias, resúmenes, suavizado…)
- **Scale**: escalado de variables (lineal, log, colores, etc.)
- **Coord**: sistema de coordenadas (cartesiano, polar…)
- **Facet**: partición de datos en subplots (paneles)

Un dataset sencillo



x	y	forma
25	11	circulo
0	0	circulo
75	53	cuadrado
200	300	cuadrado

Objetos gráficos producidos

Gramática de los gráficos

Objetos geométricos

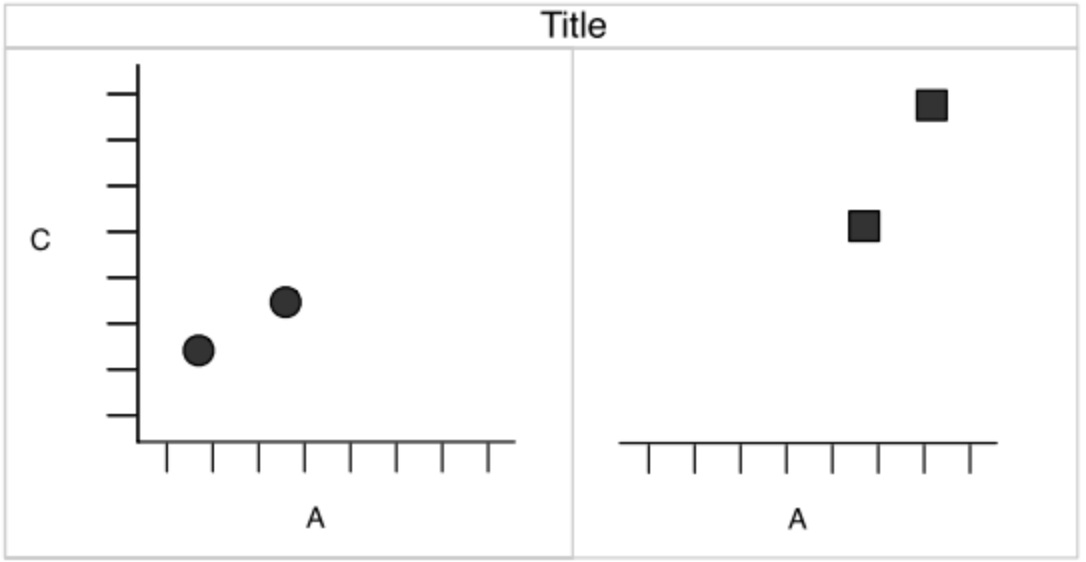
Escala y sistema de coordenadas

Anotaciones



Facets

x	y	forma
25	11	circulo
0	0	circulo
75	53	cuadrado
200	300	cuadrado



Un panel por cada tipo en la variable **forma**

Primer gráfico

Carga del dataset


```
pos_x <- c(25,0,75,200)
pos_y <- c(11,0,53,300)
forma <- c("circulo", "circulo", " cuadrado", "cuadrado")

datos <- data.frame(pos_x,pos_y,forma)

View(datos)
```

pos_x	pos_y	forma
25	11	circulo
0	0	circulo
75	53	cuadrado
200	300	cuadrado

Un template para cualquier gráfico

Primer gráfico

capa nueva

```
ggplot(data = <DATA>) +
  <GEOM_FUNCTION>(mapping = aes(<MAPPINGS>))
```

- **DATA**: los datos
- **GEOM_FUNCTION**: tipo de objetos geométricos (puntos, barras, densidad, boxplot,…)
- **MAPPINGS**: relaciona cada variable con su eje (`x = var1, y = var2`)

Creación de gráfico a partir de los datos

Primer gráfico

```
ggplot(data = datos) +
       geom_point(aes(x = pos_x, y = pos_y))
```

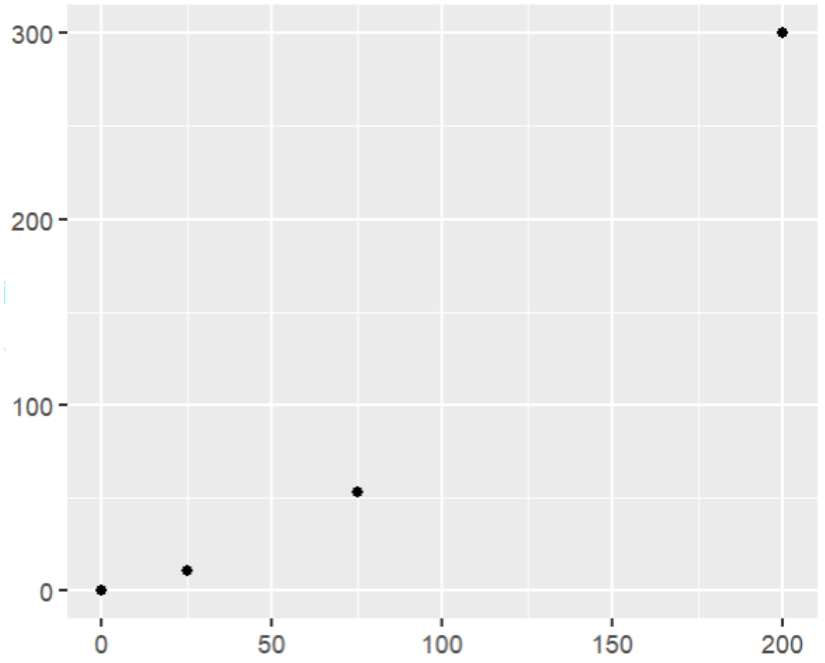


Gráfico de dispersión

Creación de gráfico a partir de los datos

Primer gráfico

```
ggplot(data = datos) +
      geom_point(aes(x = pos_x, y = pos_y, shape = forma))
```

La estética incluye cosas como el tamaño (**size**), la forma (**shape**) o el color de los puntos (**color**). Puede mostrar un punto de diferentes formas cambiando los valores de sus propiedades estéticas.

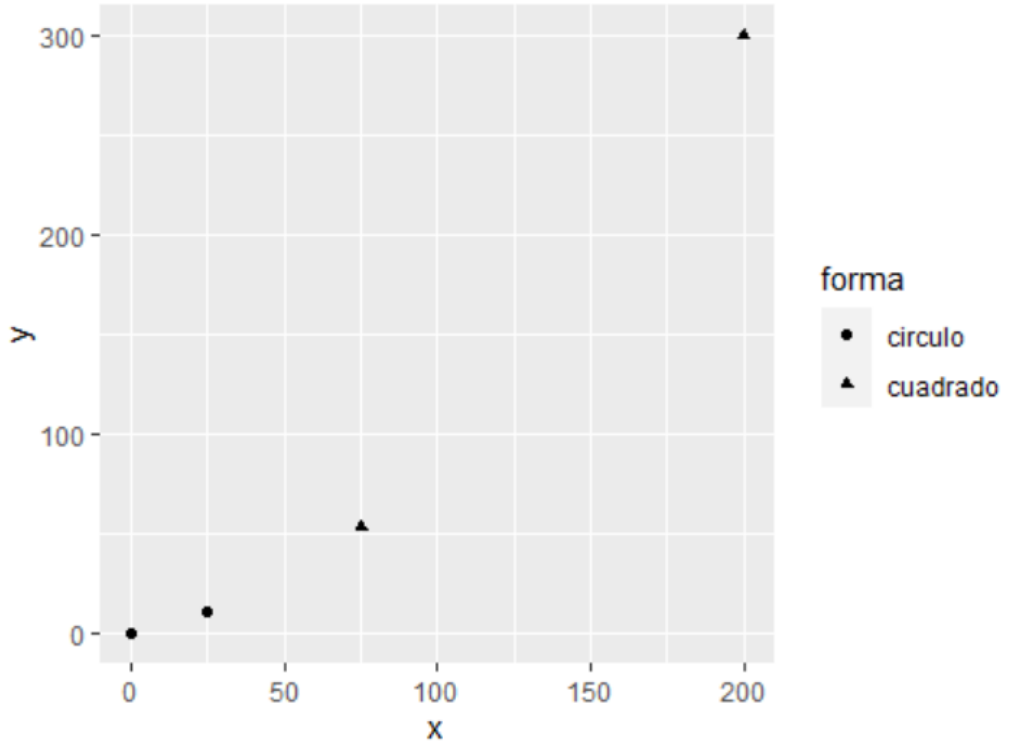
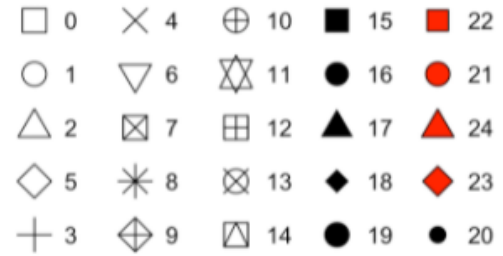


Gráfico de dispersión

Creación de gráfico a partir de los datos

Primer gráfico

```
ggplot(data = datos) +
      geom_point(aes(x = pos_x, y = pos_y, shape = forma)) +
      scale_shape_manual(values =c(16,15))
```



Cuando se mapea una variable en **aes()** ggplot2 asigna automáticamente un nivel único de la estética (aquí un color único) a cada valor único de la variable, un proceso conocido como **scaling**

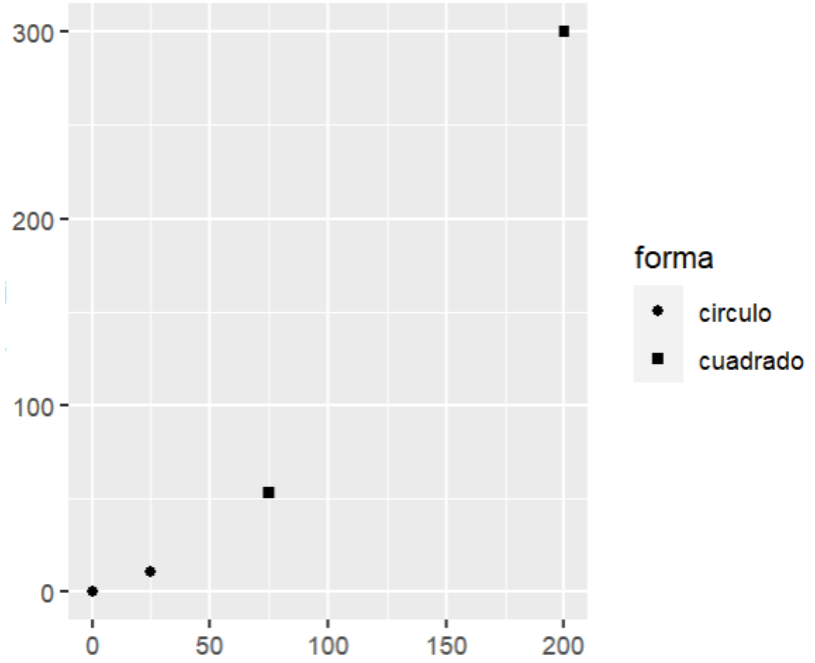


Gráfico de dispersión

Creación de gráfico a partir de los datos

Primer gráfico

```
ggplot(data = datos) +
        geom_point(aes(x = pos_x, y = pos_y, shape = forma), size = 5, color = "red") +
        scale_shape_manual(values =c(16,15))
```

Se pueden asignar valores de estéticas manualmente, ajustándolos por fuera del **aes()**

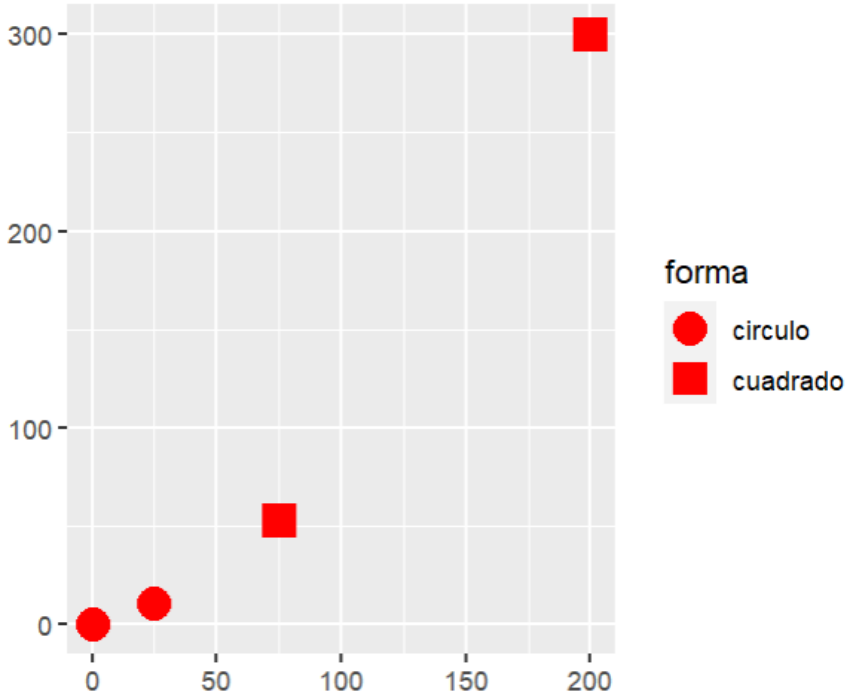


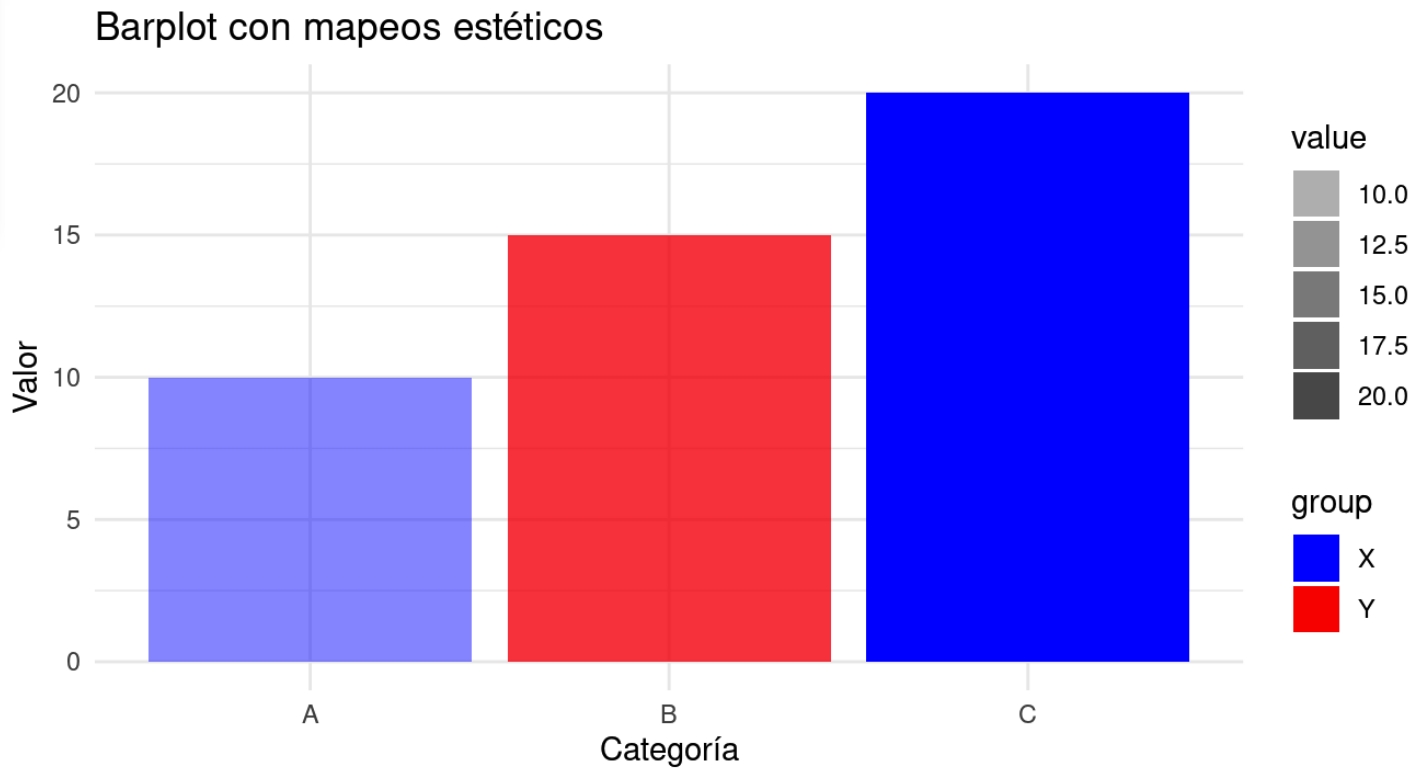
Gráfico de dispersión

Práctica con datasets sencillos

Práctica con diferentes datos

Práctica con datasets sencillos

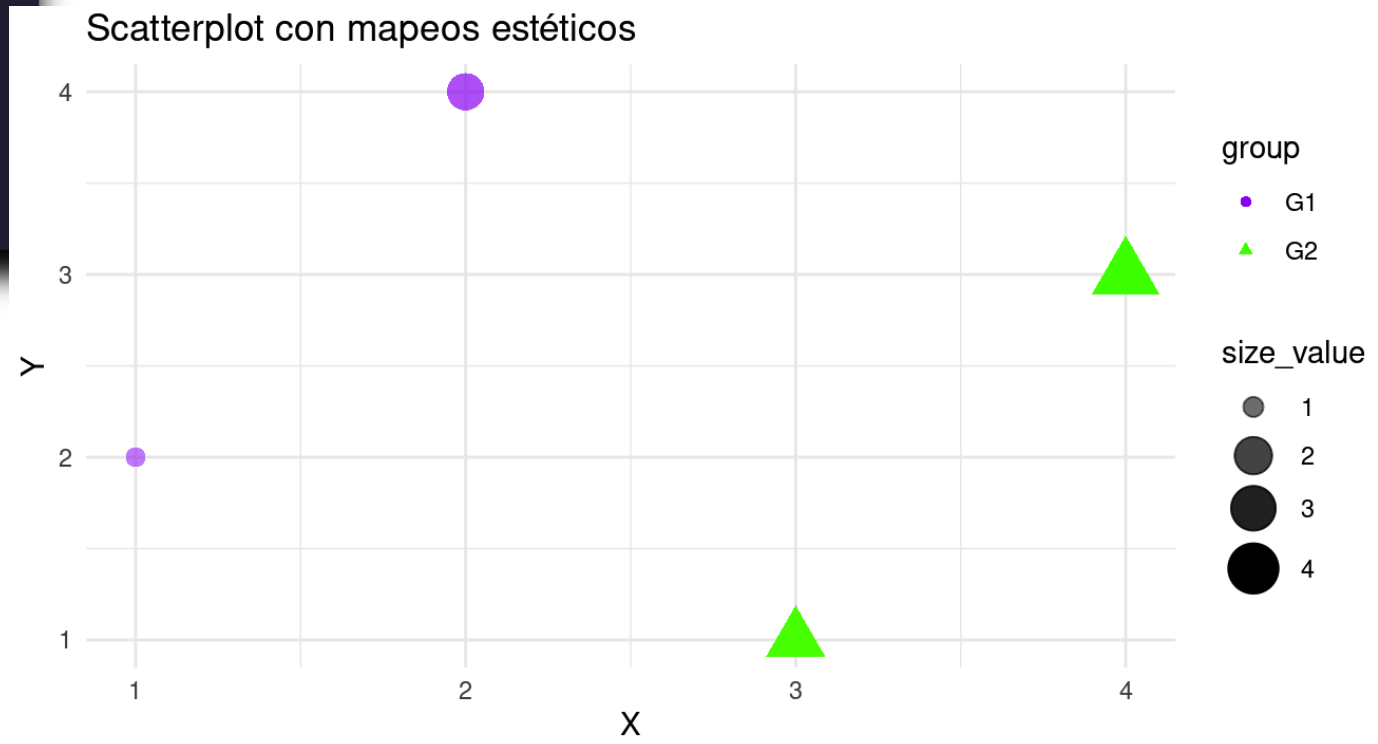
```r
data_bar <- data.frame(
  category = c("A", "B", "C"),
  value = c(10, 15, 20),
  group = c("X", "Y", "X")
)
```



Práctica con diferentes datos

Práctica con datasets sencillos

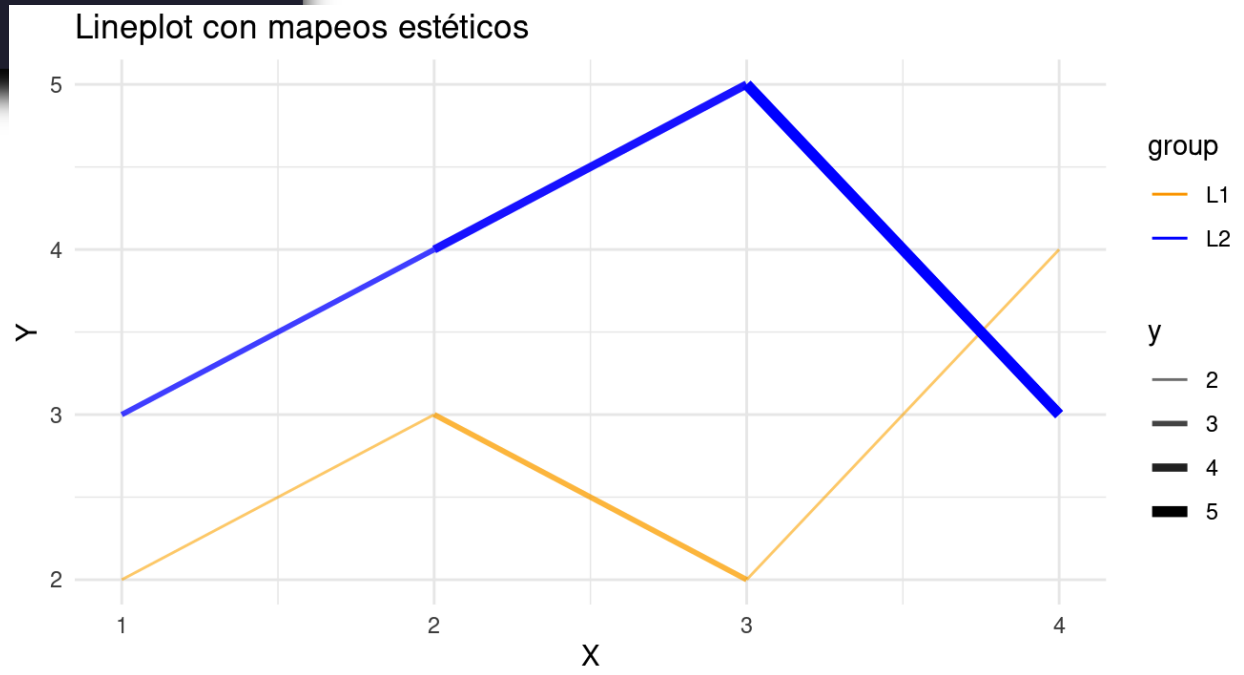
```r
data_scatter <- data.frame(
  x = c(1, 2, 3, 4),
  y = c(2, 4, 1, 3),
  group = c("G1", "G1", "G2", "G2"),
  size_value = c(1, 2, 3, 4)
)
```



Práctica con diferentes datos

Práctica con datasets sencillos

```r
data_line <- data.frame(
  x = c(1, 2, 3, 4, 1, 2, 3, 4),
  y = c(2, 3, 2, 4, 3, 4, 5, 3),
  group = c("L1", "L1", "L1", "L1", "L2", "L2", "L2", "L2")
)
```



Soluciones

Práctica con datasets sencillos

5_visualizacion.R

Run | Source

```r

# ------- Solución de actividades PLOTS --------------

# 1. BARPLOT
# Dataset mínimo para barplot (3 categorías)
data_bar <- data.frame(
  category = c("A", "B", "C"),
  value = c(10, 15, 20),
  group = c("X", "Y", "X")
)

# Barplot con mapeos estéticos
bar_plot <- ggplot(data_bar, aes(x = category, y = value, fill = group, alpha = val
  geom_bar(stat = "identity", position = "dodge") +  # position: dodge para barras
  scale_fill_manual(values = c("X" = "blue", "Y" = "red")) +  # color/fill por grup
  scale_alpha_continuous(range = c(0.4, 1)) +  # alpha basado en value
  theme_minimal() +
  labs(title = "Barplot con mapeos estéticos", x = "Categoría", y = "Valor")

print(bar_plot)
```

https://github.com/maorjuela73/taller-knuth/blob/main/5_visualizacion.R

Datos de ejemplo

Conjuntos de datos de ejemplo

- **mpg**: dataset sobre rendimiento de autos, útil para explorar relaciones entre variables como consumo y cilindrada (disponible en ggplot2)
- **faithful**: datos de actividad del géiser Old Faithful (tiempos y duraciones), excelente para histogramas o series temporales
- **PlantGrowth**: datos sobre crecimiento de plantas en diferentes tratamientos (idóneo para gráficos de caja)

Estos datasets vienen integrados en R base o en paquetes comunes, listos para usar sin descarga adicional

El dataframe `mpg`

Datos de ejemplo

Contiene observaciones recolectadas por la EPA sobre 38 modelos de autos

Entre las variables tenemos

- displ: tamaño del motor en litros
- hwy: Eficiencia del combustible en carretera

Actividad

Tu turno

1. Ejecuta `ggplot(data = mpg)`. ¿Qué ves?
2. ¿Cuántas filas y columnas tiene el dataset `mpg`?
3. ¿Qué quiere decir la variable `drv`? Revisa la ayuda
4. Elabora un gráficos de dispersion entre `hwy` y `cyl`.
5. ¿Qué pasa si hacemos un gráficos de dispersion de `class` y `drv`? ¿Por qué no es de utilidad el gráfico?

El dataframe `mpg`

Contiene observaciones recolectadas por la EPA sobre 38 modelos de autos

Entre las variables tenemos

- displ: tamaño del motor en litros
- hwy: Eficiencia del combustible en carretera

Tipos de variables

Tipos de variables

Tipos de variables

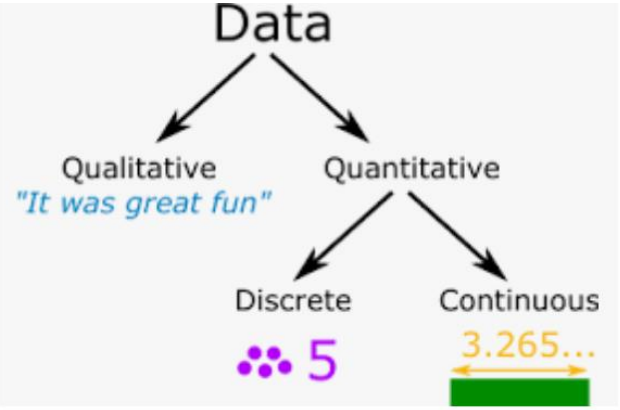
Característica (Variable)

Según su forma de ser descritas

- Cualitativa
- Cuantitativa

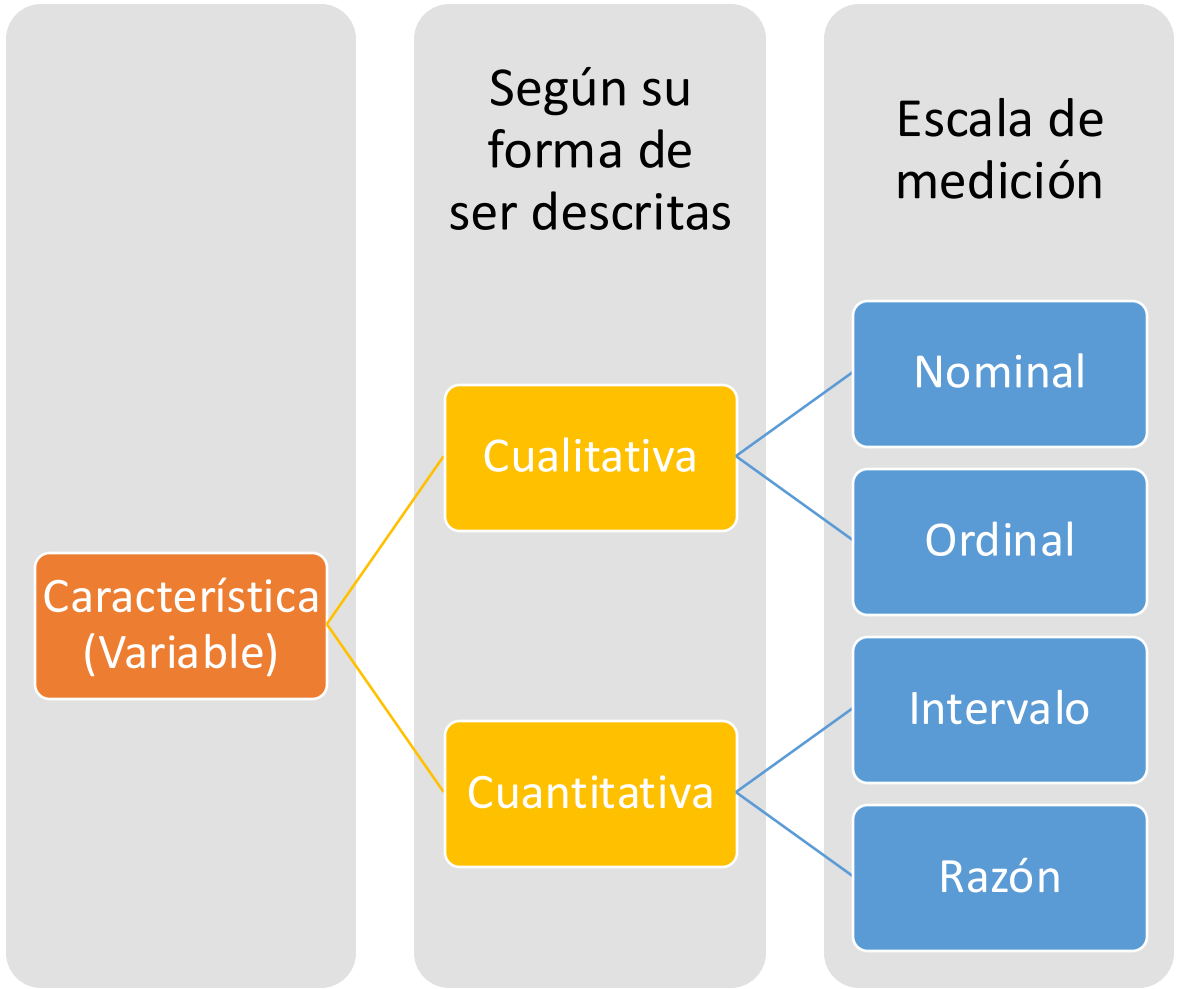
Tipo de variables

- Discreta → Números enteros, No valores intermedios, p.ej. núm. de mascotas
- Contínua → Admite valores fraccionarios, p.ej. estatura



Escalas de medición

Tipos de variables

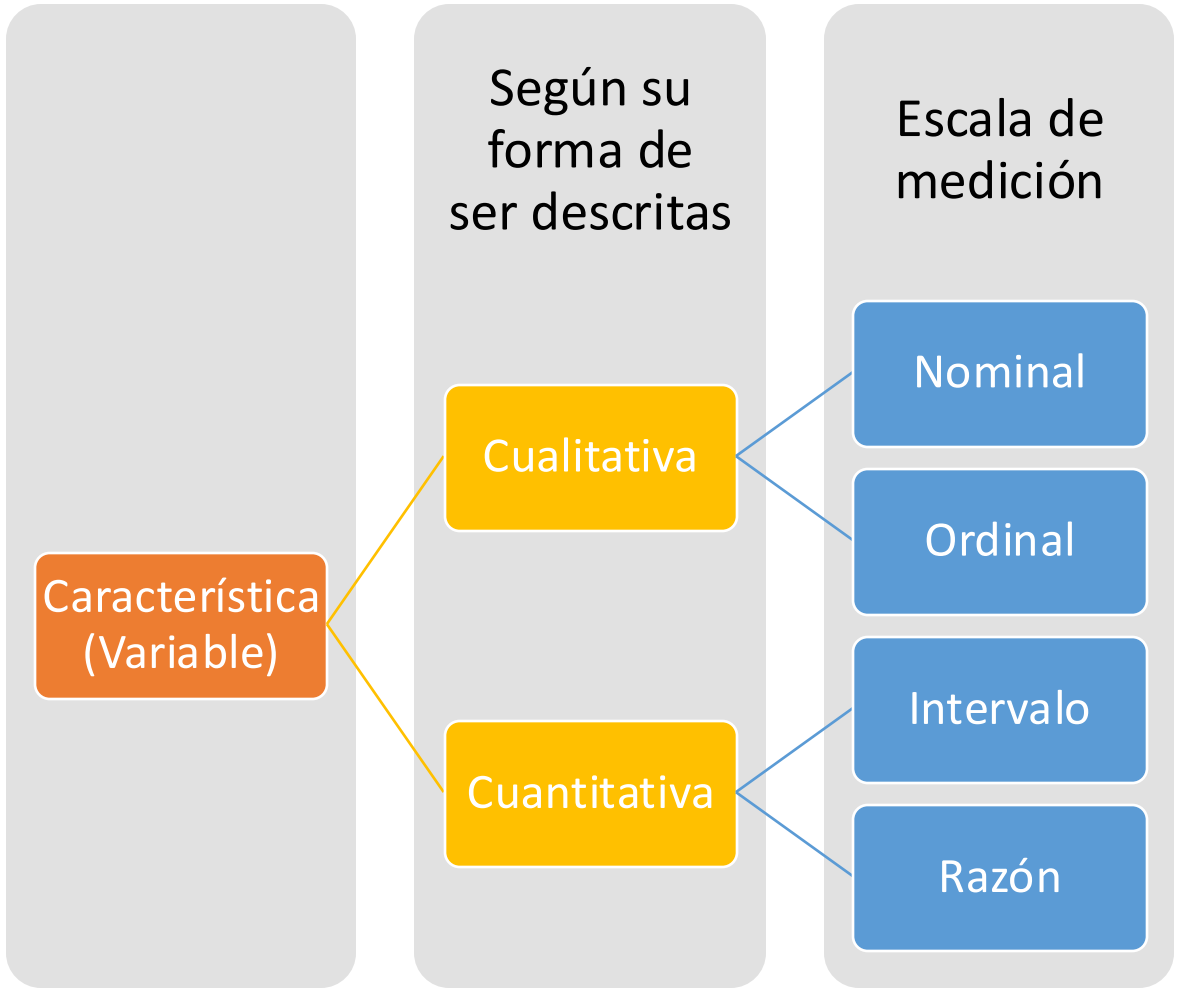


Etiquetas, sin orden

color_ojos
Negro
Verde
Azul

Escalas de medición

Tipos de variables



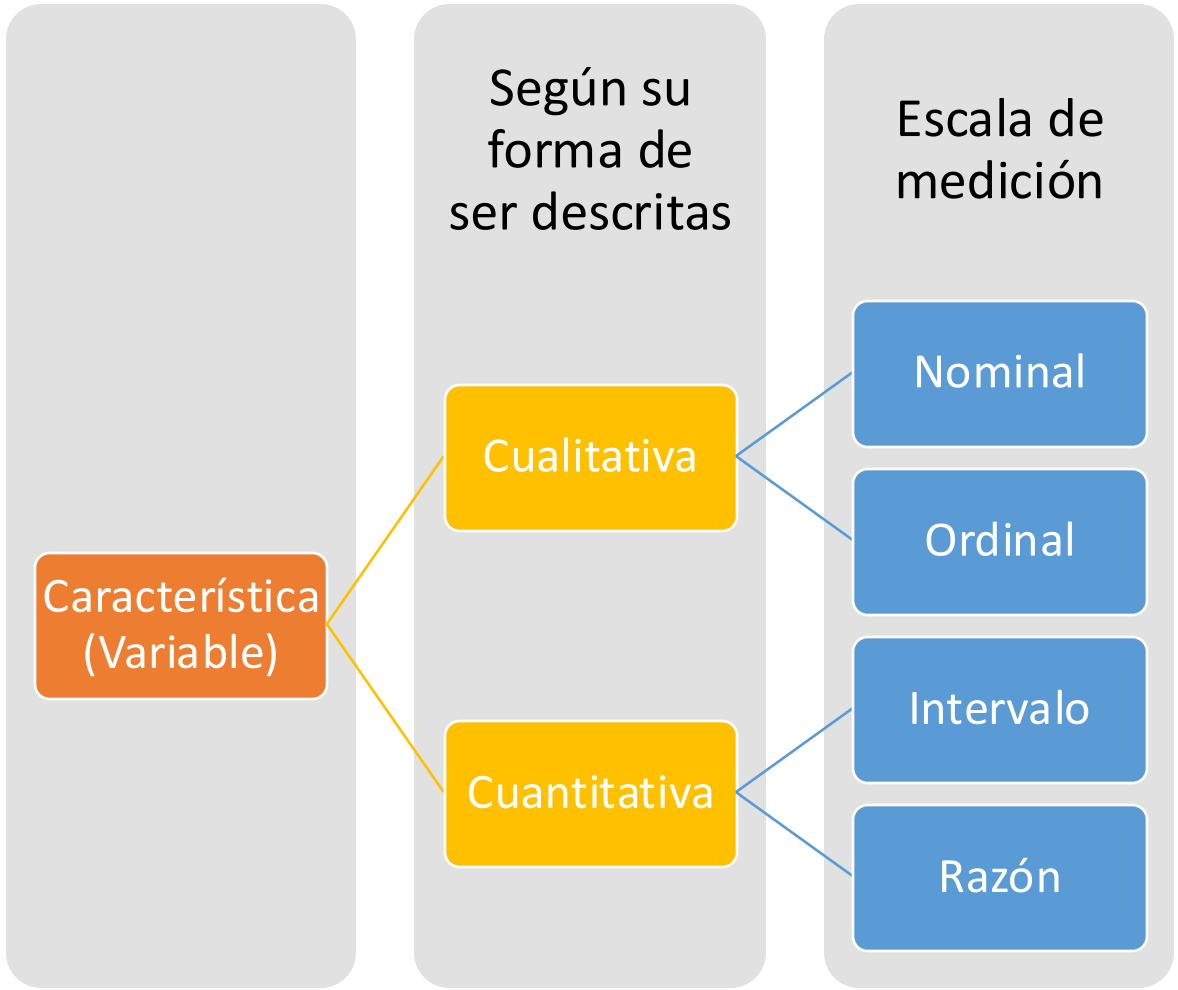
estado_salud
Muy saludable
Medianamente saludable
Saludable
Poco saludable
No saludable

Etiquetas, con orden

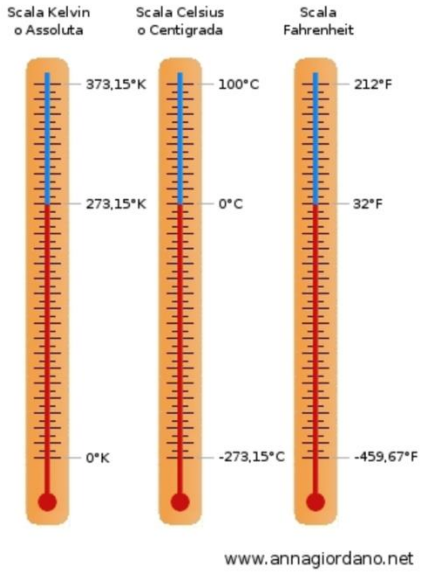
nivel_socioeconómico
Alto
Medio
Bajo

Escalas de medición

Tipos de variables



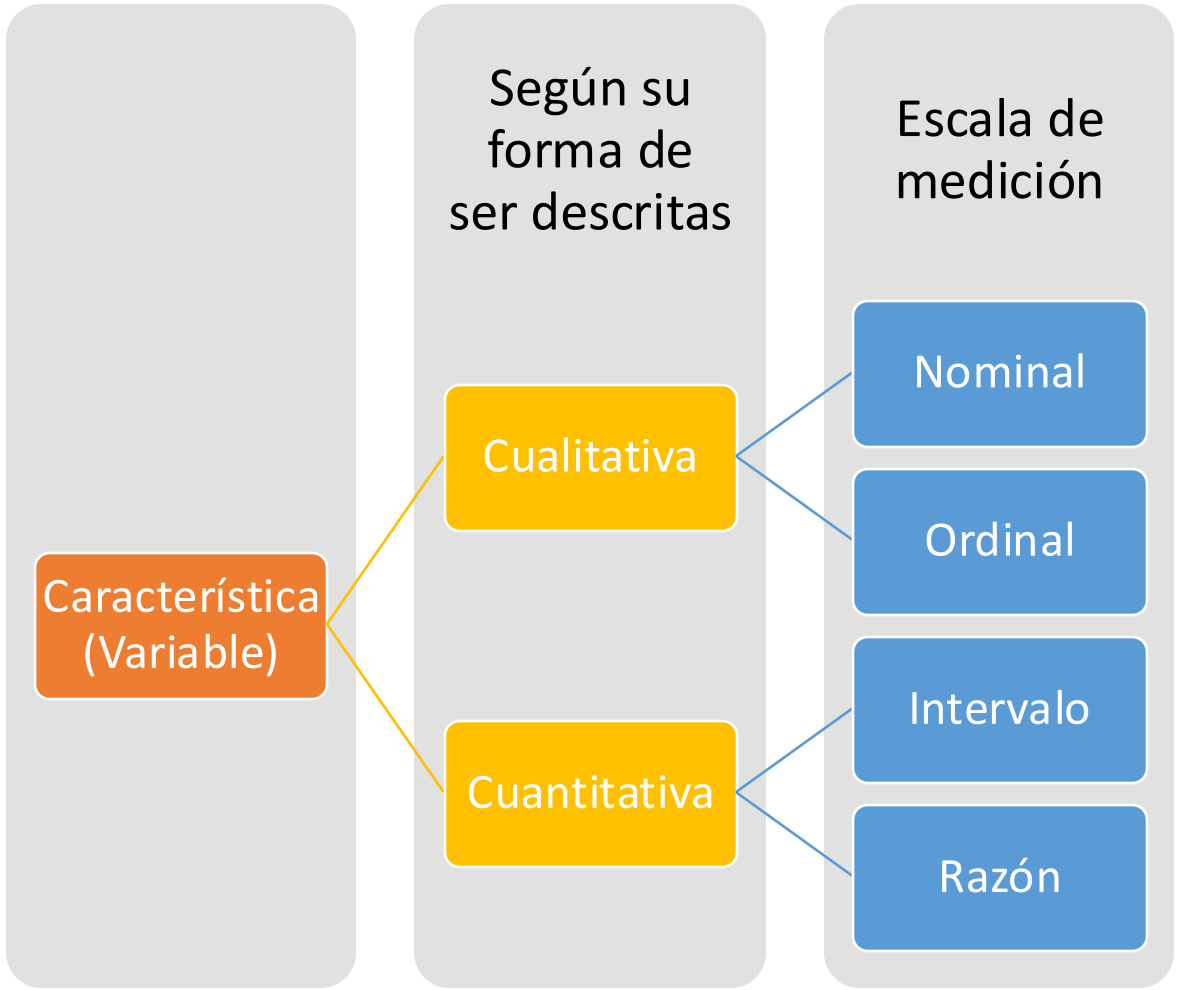
temp_c
36.8
38.4
37.1



Valores numéricos.
Unidades de medidas constantes.
Se conoce la distancia exacta entre mediciones.
Se pueden hacer comparaciones entre la diferencia de mediciones.
El cero es una **convención**.

Escalas de medición

Tipos de variables



precio
$5000
$3200
$0

Valores numéricos.
Unidades de medidas constantes.
Se conoce la distancia exacta entre mediciones.
Se pueden hacer comparaciones entre la diferencia de mediciones.
El cero es **absoluto**, representa **ausencia** de lo que se mide.

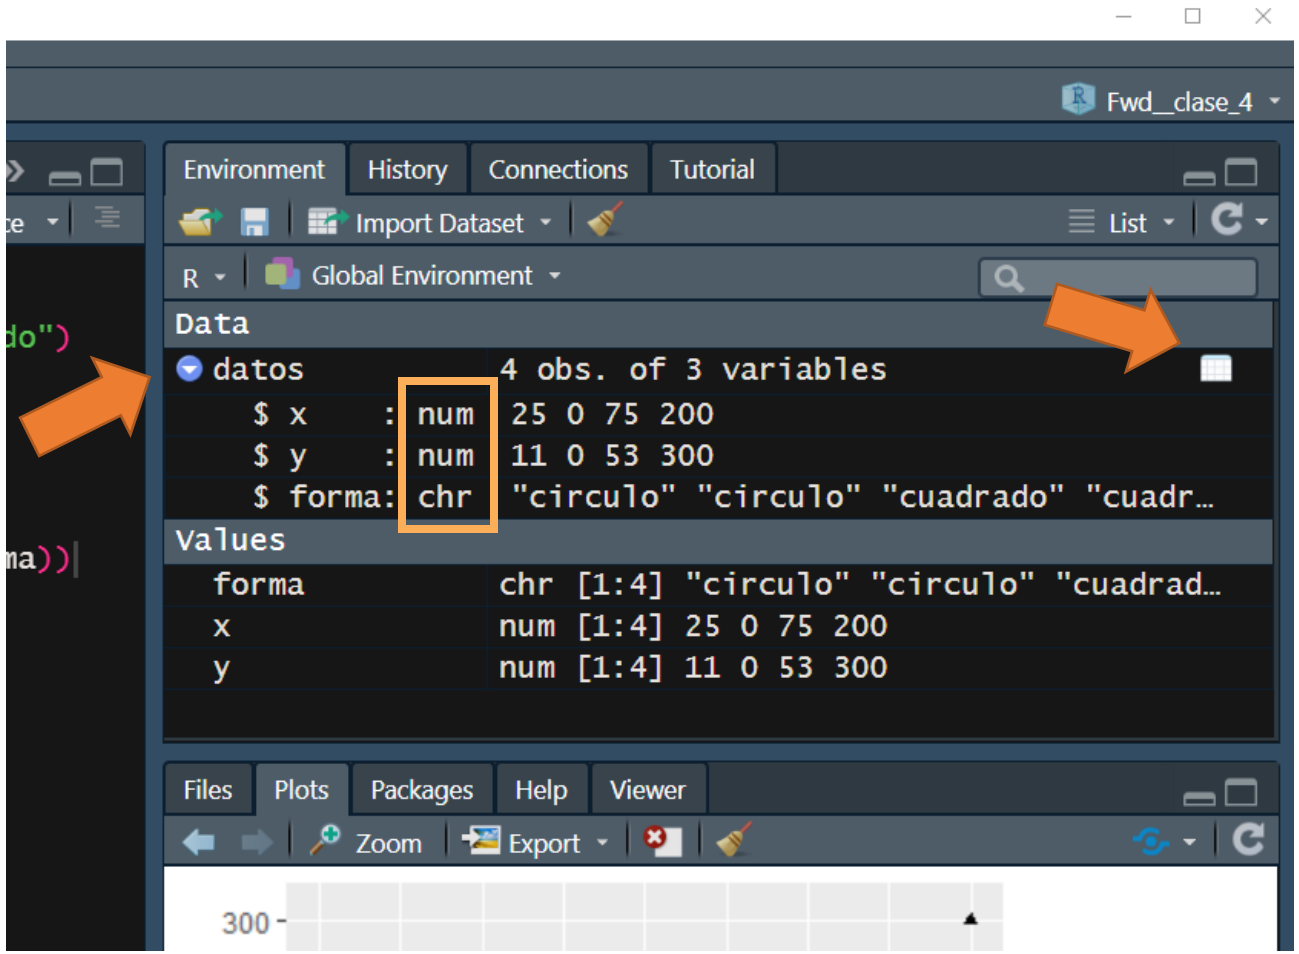
Escala de medición y sus operaciones posibles

Tipos de variables

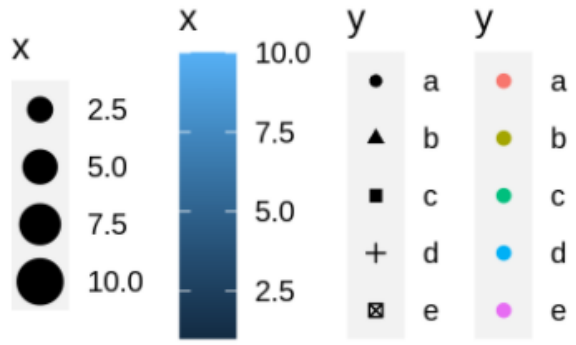
Nivel de medición	**Identificación:** Hay distinción entre categorías	**Orden:** Se pueden ordenar	**Unidad de medida constante:** Se conoce la distancia exacta entre cada categoría	**Cero absoluto:** Ausencia de valor en la escala que se traduzca
Operaciones	Contar	Ordenar	Comparar diferencias	Comparar razones
Relaciones posibles	$=, \neq$	$<, >$	$+, -$	$\times, \div$
Nominal	✓			
Ordinal	✓	✓		
Intervalo	✓	✓	✓	
Razón	✓	✓	✓	✓

Tipos de datos en R

Tipos de variables



Abreviación	Significado
int	Número entero
num,	Número real
chr	Cadena de caracteres
POSIXct	Fecha/Hora
Factor	Categorías



Algunas transformaciones estadísticas suministradas por ggplot2

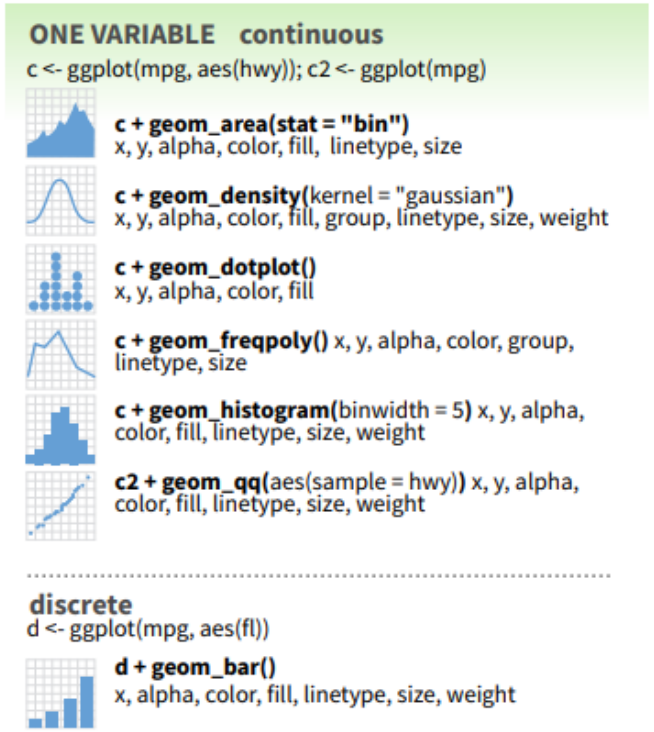
Gráficos más importantes para describir datos

Name	Description
bin	Divide continuous range into bins, and count number of points in each
boxplot	Compute statistics necessary for boxplot
contour	Calculate contour lines
density	Compute 1d density estimate
identity	Identity transformation, $f(x) = x$
jitter	Jitter values by adding small random value
qq	Calculate values for quantile-quantile plot
quantile	Quantile regression
smooth	Smoothed conditional mean of y given x
summary	Aggregate values of y for given x
unique	Remove duplicated observations

Gráficos más importantes para describir datos

De una variable

Gráficos más importantes para describir datos



https://www.maths.usyd.edu.au/u/UG/SM/STAT3022/r/current/Misc/data-visualization-2.1.pdf

Dos variables

Gráficos más importantes para describir datos

TWO VARIABLES

continuous x , continuous y

e <- ggplot(mpg, aes(cty, hwy))



e + geom_label(aes(label = cty), nudge_x = 1, nudge_y = 1, check_overlap = TRUE**)** x, y, label, alpha, angle, color, family, fontface, hjust, lineheight, size, vjust



e + geom_jitter(height = 2, width = 2**)** x, y, alpha, color, fill, shape, size



e + geom_point(), x, y, alpha, color, fill, shape, size, stroke



e + geom_quantile(), x, y, alpha, color, group, linetype, size, weight



e + geom_rug(sides = "bl"**)**, x, y, alpha, color, linetype, size



e + geom_smooth(method = lm**)**, x, y, alpha, color, fill, group, linetype, size, weight



e + geom_text(aes(label = cty), nudge_x = 1, nudge_y = 1, check_overlap = TRUE**)**, x, y, label, alpha, angle, color, family, fontface, hjust, lineheight, size, vjust

discrete x , discrete y

g <- ggplot(diamonds, aes(cut, color))



g + geom_count(), x, y, alpha, color, fill, shape, size, stroke

discrete x , continuous y

f <- ggplot(mpg, aes(class, hwy))



f + geom_col(), x, y, alpha, color, fill, group, linetype, size



f + geom_boxplot(), x, y, lower, middle, upper, ymax, ymin, alpha, color, fill, group, linetype, shape, size, weight



f + geom_dotplot(binaxis = "y", stackdir = "center"**)**, x, y, alpha, color, fill, group



f + geom_violin(scale = "area"**)**, x, y, alpha, color, fill, group, linetype, size, weight

continuous function

i <- ggplot(economics, aes(date, unemploy))



i + geom_area()
x, y, alpha, color, fill, linetype, size



i + geom_line()
x, y, alpha, color, group, linetype, size



i + geom_step(direction = "hv")
x, y, alpha, color, group, linetype, size

https://www.maths.usyd.edu.au/u/UG/SM/STAT3022/r/current/Misc/data-visualization-2.1.pdf

Gracias por tu asistencia y participación ☺

Contacto

miguela.orjuela@urosario.edu.co

https://www.linkedin.com/in/miguel-orjuela/

https://github.com/maorjuela73

Links de interés

- *https://ggplot2-book.org/*
- *https://r4ds.had.co.nz/*
- *https://raw.githubusercontent.com/rstudio/cheatsheets/main/data-visualization.pdf*
- *https://clauswilke.com/dataviz/*