Universidad del Rosario | Escuela de Ciencias e Ingeniería | DEPE

IMPORTACIÓN DE DATOS CON R

SÁBADO 20 DE SEPTIEMBRE | **10:00 AM A 12:00 PM**

En esta sesión de dos horas, nos sumergiremos en los conceptos básicos y las mejores prácticas relacionadas con la importación de datos en R.

Taller Knuth

MODALIDAD ACCESO REMOTO

NO SE REQUIERE EXPERIENCIA PREVIA EN PROGRAMACIÓN

Sobre el conferencista



Miguel Angel Orjuela Rocha

Ing. de Sistemas y Computación

Skills:

- Desarrollo Fullstack
- Analítica de datos
- Transferencia de conocimiento

Contacto:

miguela.orjuela@urosario.edu.co

https://www.linkedin.com/in/miguel-orjuela/

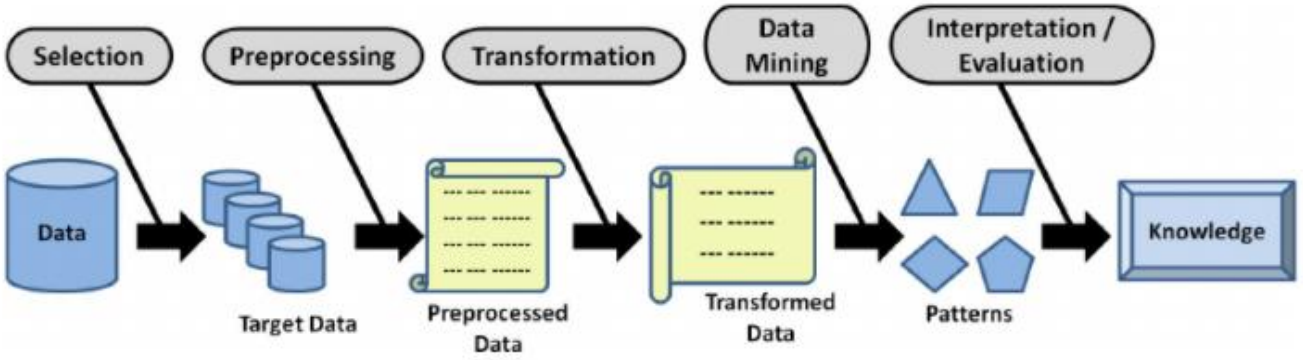
https://github.com/maorjuela73

Contenido

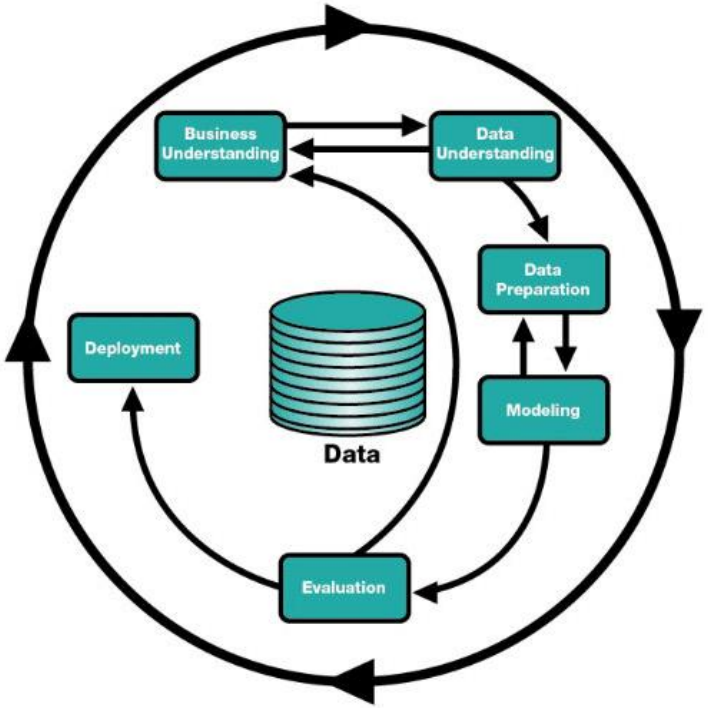
- Introducción
- Herramientas a emplear
- Diferentes formatos de datos
- Lectura de archivos planos
- La librería readr
- Lectura de archivos de Excel

Introducción

Metodologías de analítica famosas



Knowledge Discovery on Databases (KDD)



Cross Industry Standard Process for Data Mining (CRISP-DM)

Algunas preguntas

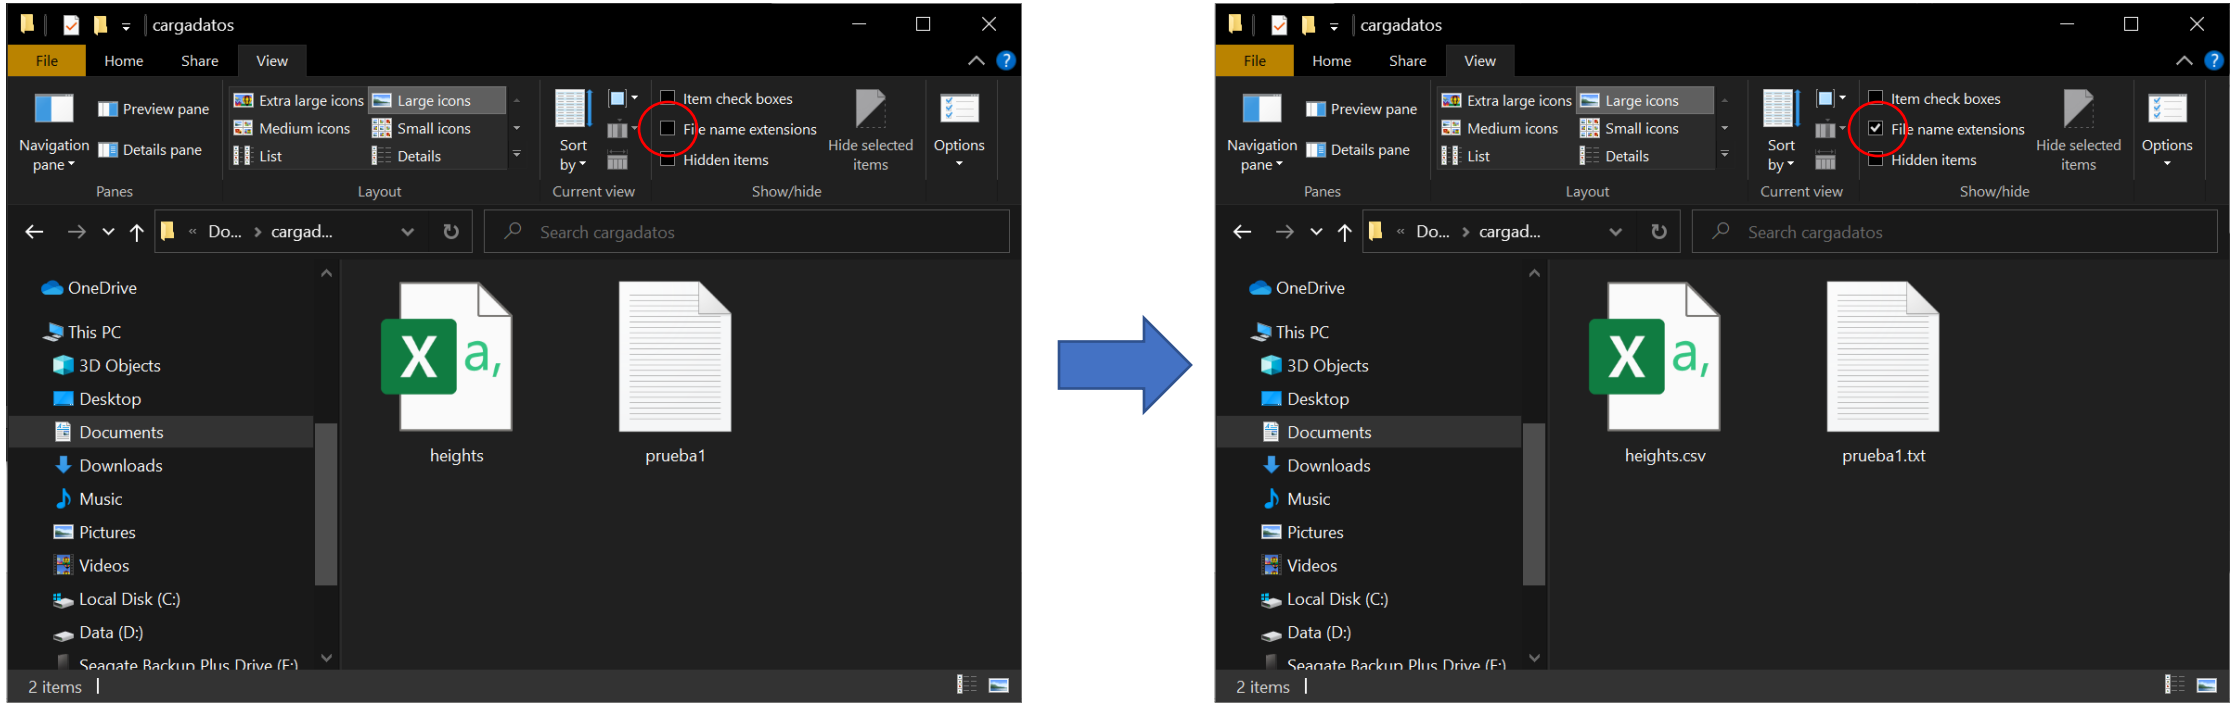
- ¿Qué es la extensión de un archivo?



- ¿Qué significan las extensiones csv, xlsx, txt?
- ¿Dónde están los datos que usualmente cargamos para análisis?

Una recomendación

Activar la opción para ver las extensiones de archivos



Herramientas a emplear

RStudio Cloud

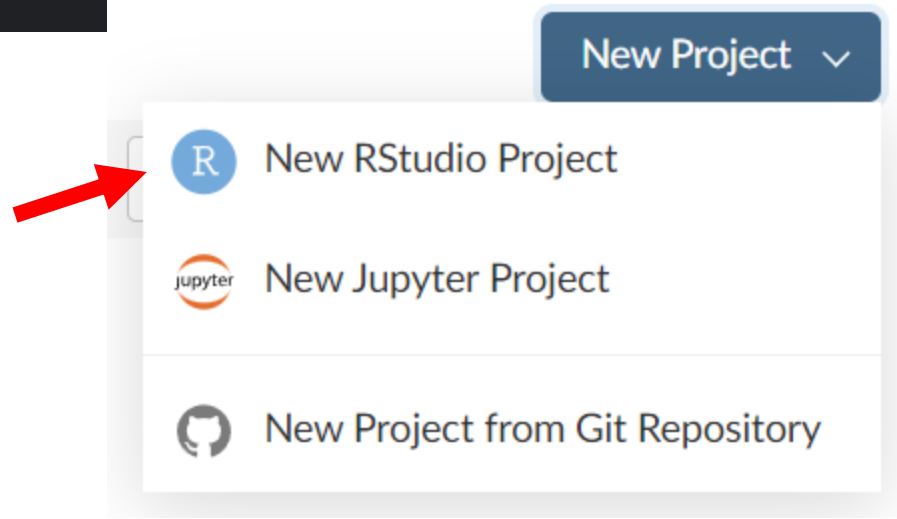
- Servicio web que permite ejecutar R en la nube (servidores de RStudio)

https://rstudio.cloud ▾ Traducir esta página

RStudio Cloud

RStudio Cloud is a lightweight, cloud-based solution that allows anyone to do, share, teach and learn data science online. ... There is nothing to configure and ...

- Se inicia sesión y se crea un nuevo proyecto



Diferentes formatos de datos

Según su estructura

Diferentes formatos de datos

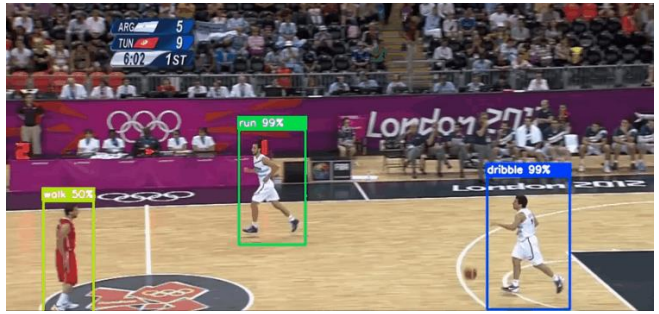
Datos Estructurados

	nombre	color	edad	altura	peso	puntuacion
1:	Paco	Rojo	24	182	74.8	83
2:	Juan	Green	30	170	70.1	500
3:	Andres	Amarillo	41	169	60.0	20
4:	Natalia	Green	22	183	75.0	865
5:	Vanesa	Verde	31	178	83.9	221
6:	Miriam	Rojo	35	172	76.2	413
7:	Juan	Amarillo	22	164	68.0	902

Datos Semi-Estructurados


```
{
  "marcadores": [
    {
      "latitude": 40.416875,
      "longitude": -3.703308,
      "city": "Madrid",
      "description": "Puerta del Sol"
    },
    {
      "latitude": 40.417438,
      "longitude": -3.693363,
      "city": "Madrid",
      "description": "Paseo del Prado"
    },
```

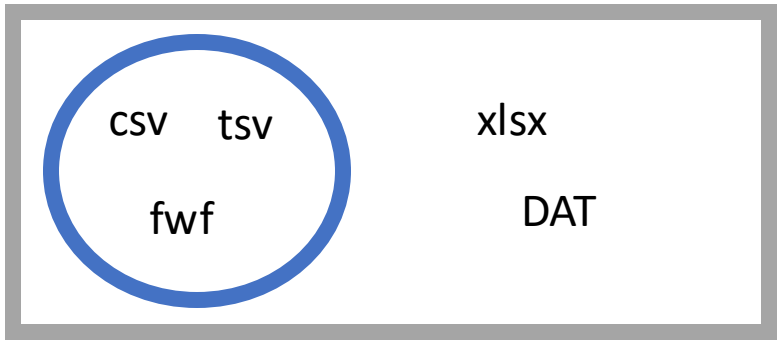

Datos NO Estructurados



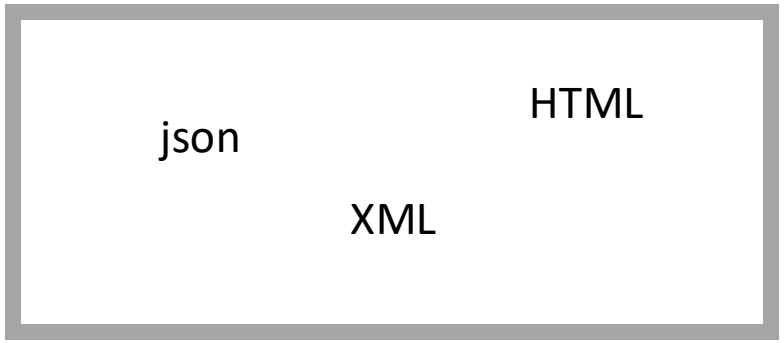
Según su ubicación

Diferentes formatos de datos

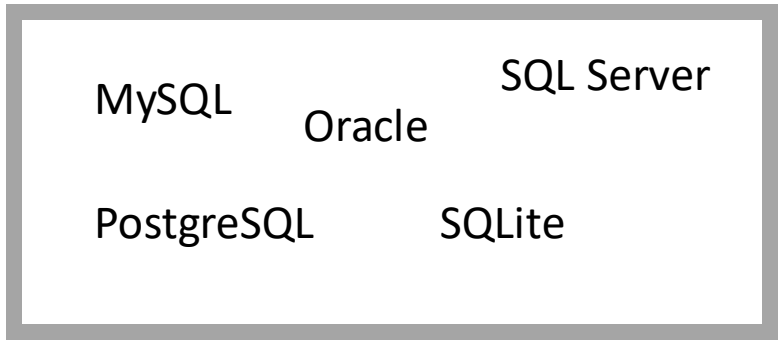
En el disco duro



En la web



En una base de datos



Lectura de archivos planos

Algunas herramientas básicas

Editor de archivos de texto plano

- Notepad de Windows
- Sublime Text
- Notepad++
- Visual Studio Code
- Atom
- Vim
- …

Librerías de carga de datos de R

- utils
- readr
- readxl

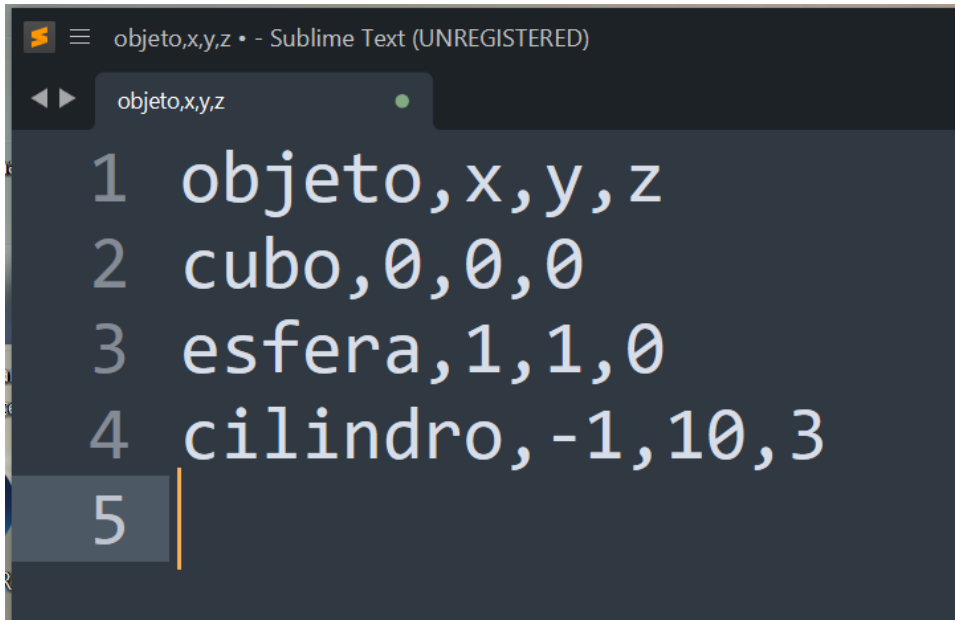
Parámetros de una función de carga

- Archivo (file): el nombre de un archivo o una conexión
- Encabezado (header): Valor lógico que indica si el archivo tiene una línea de encabezado
- Separador: una cadena que indica cómo se separan las columnas (p.ej, por comas, por tabs, por algún símbolo raro)
- Clases de columnas: Datos que indica la clase de cada columna en el conjunto de datos.
- Filas a saltar: el número de líneas para saltar desde el principio
- …

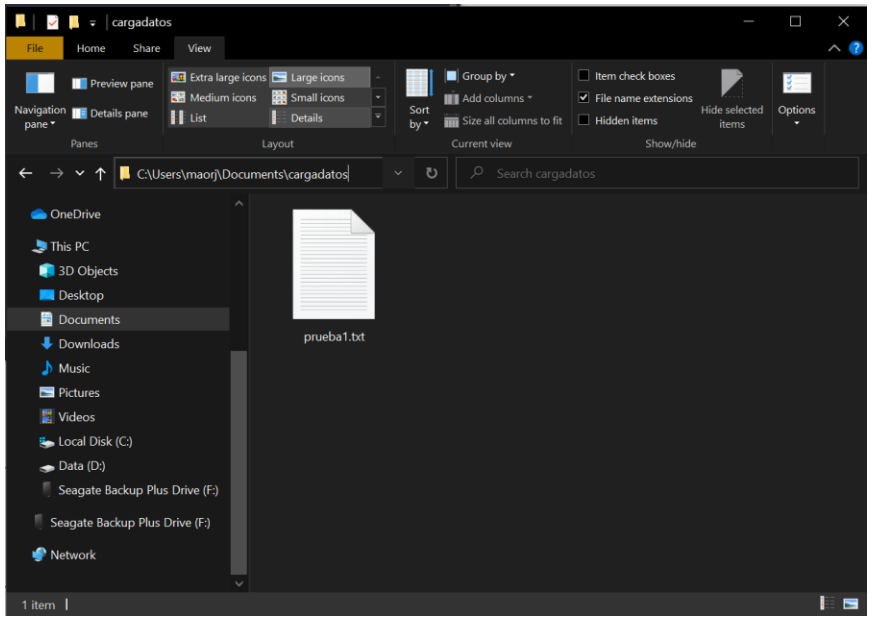
Archivo de prueba # 1

Lectura de archivos planos

1. Abrir el editor de texto de preferencia y escribir lo siguiente:



2. Guardar el archivo en una carpeta



Carga del archivo con librería utils

Las funciones read.* permiten cargar datos

```
x <- read.csv("cargadatos/prueba1.txt")
```

```
x <- read.table("cargadatos/prueba1.txt")
```

Existen varias formas de usar las funciones read.*

- Revisar la documentación (F1)

Archivo de prueba # 2

Descarga el siguiente archivo

https://raw.githubusercontent.com/hadley/r4ds/master/data/heights.csv

Comprueba el separador de columnas en el archivo con un editor de texto

- ¿Son comas? ¿Son puntos y comas? ¿Son tabs? ¿Son caracteres raros?

Selecciona el método adecuado para cargar el archivo (Ver documentación)

```
x <- read.csv("cargadatos/heights.csv")
```

```
read.table(file, header = FALSE, sep = "", quote = "\"'",
           dec = ".", numerals = c("allow.loss", "warn.loss", "no.loss"),
           row.names, col.names, as.is = !stringsAsFactors,
           na.strings = "NA", colClasses = NA, nrows = -1,
           skip = 0, check.names = TRUE, fill = !blank.lines.skip,
           strip.white = FALSE, blank.lines.skip = TRUE,
           comment.char = "#",
           allowEscapes = FALSE, flush = FALSE,
           stringsAsFactors = FALSE,
           fileEncoding = "", encoding = "unknown", text, skipNul = FALSE)

read.csv(file, header = TRUE, sep = ",", quote = "\"",
         dec = ".", fill = TRUE, comment.char = "", ...)

read.csv2(file, header = TRUE, sep = ";", quote = "\"",
          dec = ",", fill = TRUE, comment.char = "", ...)

read.delim(file, header = TRUE, sep = "\t", quote = "\"",
           dec = ".", fill = TRUE, comment.char = "", ...)

read.delim2(file, header = TRUE, sep = "\t", quote = "\"",
            dec = ",", fill = TRUE, comment.char = "", ...)
```

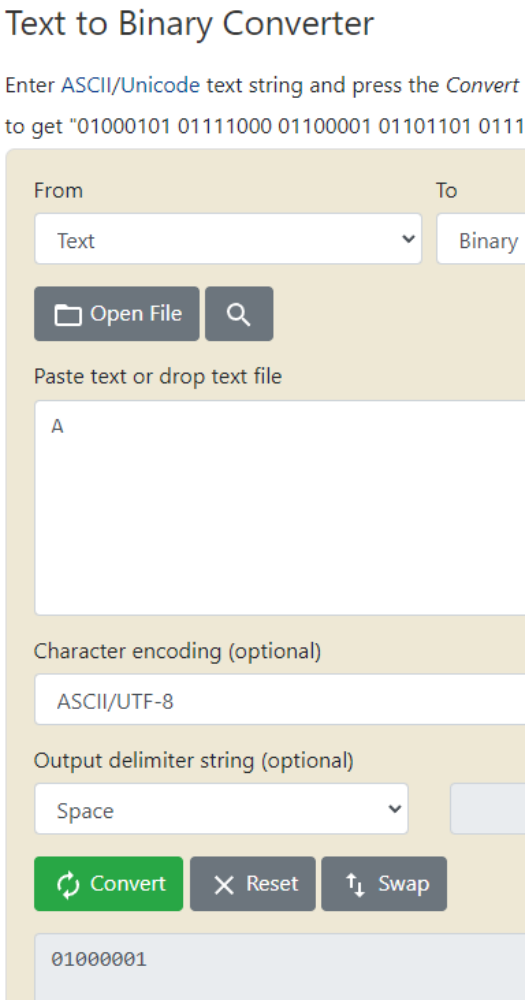
Codificación de caracteres (encoding)

Lectura de archivos planos

Proceso de asignación de números a caracteres gráficos

USASCII code chart

Bits $b_7 b_6 b_5$ →	0 0 0	0 0 1	0 1 0	0 1 1	1 0 0	1 0 1	1 1 0	1 1 1
b_4 b_3 b_2 b_1 ↓ Row / Column →	0	1	2	3	4	5	6	7
0 0 0 0	0	NUL	DLE	SP	0	@	P	`	p
0 0 0 1	1	SOH	DC1	!	1	A	Q	a	q
0 0 1 0	2	STX	DC2	"	2	B	R	b	r
0 0 1 1	3	ETX	DC3	#	3	C	S	c	s
0 1 0 0	4	EOT	DC4	$	4	D	T	d	t
0 1 0 1	5	ENQ	NAK	%	5	E	U	e	u
0 1 1 0	6	ACK	SYN	&	6	F	V	f	v
0 1 1 1	7	BEL	ETB	'	7	G	W	g	w
1 0 0 0	8	BS	CAN	(	8	H	X	h	x
1 0 0 1	9	HT	EM	)	9	I	Y	i	y
1 0 1 0	10	LF	SUB	*	:	J	Z	j	z
1 0 1 1	11	VT	ESC	+	;	K	[	k	{
1 1 0 0	12	FF	FS	,	<	L	\	l	|
1 1 0 1	13	CR	GS	-	=	M	]	m	}
1 1 1 0	14	SO	RS	.	>	N	^	n	~
1 1 1 1	15	SI	US	/	?	O	_	o	DEL



https://cs61.seas.harvard.edu/site/2020/Unicode/
https://www.rapidtables.com/convert/number/ascii-to-binary.html

Codificaciones comunes



Table for Debugging Common UTF-8 Character Encoding Problems.

Code Point		Characters		UTF-8 Bytes	Code Point		Characters		UTF-8 Bytes
Unicode	Windows 1252	Expected	Actual		Unicode	Windows 1252	Expected	Actual	
U+20AC	0x80	€	â ,¬	%E2 %82 %AC	U+00C0	0xC0	À	Ã €	%C3 %80
	0x81				U+00C1	0xC1	Á	Ã	%C3 %81
U+201A	0x82	‚	â € š	%E2 %80 %9A	U+00C2	0xC2	Â	Ã ‚	%C3 %82
U+0192	0x83	ƒ	Æ ’	%C6 %92	U+00C3	0xC3	Ã	Ã ƒ	%C3 %83
U+201E	0x84	„	â € ž	%E2 %80 %9E	U+00C4	0xC4	Ä	Ã „	%C3 %84
U+2026	0x85	…	â € ¦	%E2 %80 %A6	U+00C5	0xC5	Å	Ã …	%C3 %85
U+2020	0x86	†	â €	%E2 %80 %A0	U+00C6	0xC6	Æ	Ã †	%C3 %86
U+2021	0x87	‡	â € ¡	%E2 %80 %A1	U+00C7	0xC7	Ç	Ã ‡	%C3 %87
U+02C6	0x88	ˆ	Ë †	%CB %86	U+00C8	0xC8	È	Ã ˆ	%C3 %88
U+2030	0x89	‰	â € °	%E2 %80 %B0	U+00C9	0xC9	É	Ã ‰	%C3 %89
U+0160	0x8A	Š	Å	%C5 %A0	U+00CA	0xCA	Ê	Ã Š	%C3 %8A
U+2039	0x8B	‹	â € ¹	%E2 %80 %B9	U+00CB	0xCB	Ë	Ã ‹	%C3 %8B
U+0152	0x8C	Œ	Å ’	%C5 %92	U+00CC	0xCC	Ì	Ã Œ	%C3 %8C
	0x8D				U+00CD	0xCD	Í	Ã	%C3 %8D
U+017D	0x8E	Ž	Å ½	%C5 %BD	U+00CE	0xCE	Î	Ã Ž	%C3 %8E
	0x8F				U+00CF	0xCF	Ï	Ã	%C3 %8F
	0x90				U+00D0	0xD0	Ð	Ã	%C3 %90
U+2018	0x91	‘	â € ˜	%E2 %80 %98	U+00D1	0xD1	Ñ	Ã ‘	%C3 %91
U+2019	0x92	’	â € ™	%E2 %80 %99	U+00D2	0xD2	Ò	Ã ’	%C3 %92
U+201C	0x93	“	â € œ	%E2 %80 %9C	U+00D3	0xD3	Ó	Ã “	%C3 %93
U+201D	0x94	”	â €	%E2 %80 %9D	U+00D4	0xD4	Ô	Ã ”	%C3 %94
U+2022	0x95	•	â € ¢	%E2 %80 %A2	U+00D5	0xD5	Õ	Ã •	%C3 %95

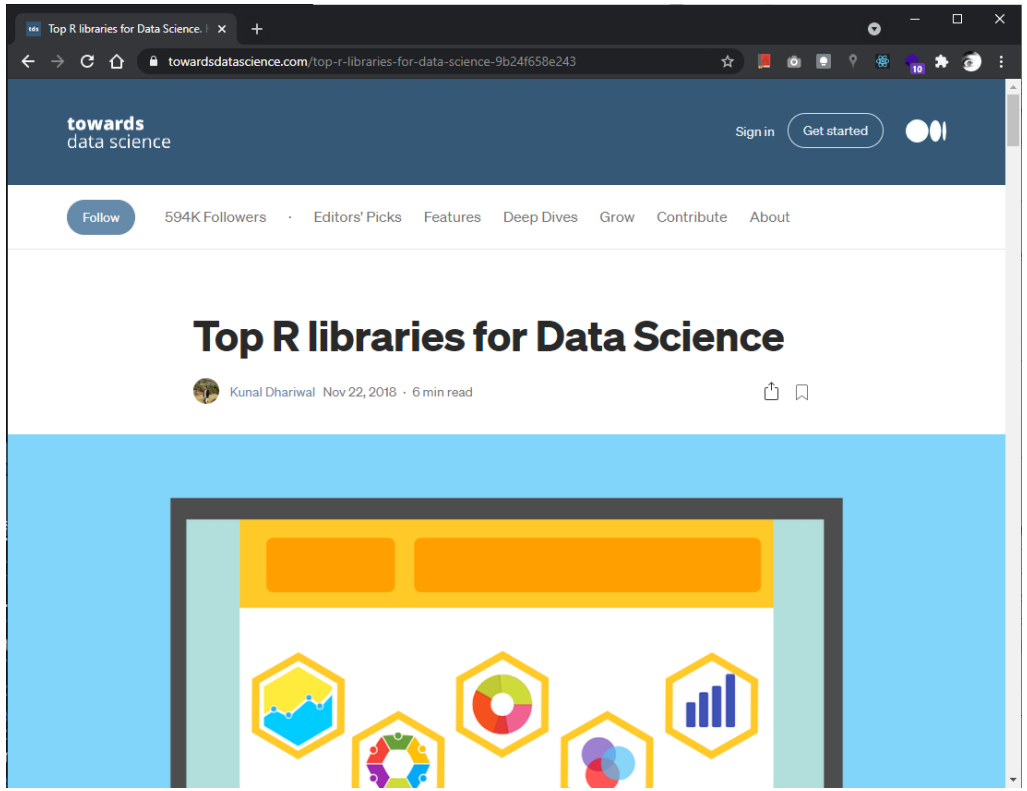
https://www.i18nqa.com/debug/utf8-debug.html

La librería **`readr`**

¿Qué es?

- Es una librería más para cargar datos
- Proporcionar una forma rápida y sencilla de leer datos rectangulares (como csv, tsv y fwf).
- Diseñada para analizar de manera flexible muchos tipos de datos que se encuentran en la naturaleza
- Muestra claramente cuando los datos fallan en cargar

Instalación de paquetes




```r
# Se necesitan instalar una vez
# por computador

install.packages("nombrepaquete")

# pero hay que cargarlo cada vez
# que se inicia R

library(nombredelpaquete)
```

Instalación de paquetes

La librería readr

```
# librerías importantes

library(readr)

library(tidyr)

library(dplyr)

library(ggplot2)
```



Paquete **tidyverse**

`library(tidyverse)` las incluye todas

```
> library(tidyverse)
-- Attaching packages --------------- tidyverse 1.3.1 --
v ggplot2 3.3.3     v purrr   0.3.4
v tibble  3.1.1     v dplyr   1.0.5
v tidyr   1.1.3     v stringr 1.4.0
v readr   1.4.0     v forcats 0.5.1
-- Conflicts ------------------ tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
x dplyr::lag()    masks stats::lag()
```

Modo de uso

Tiene funciones muy parecidas a las funciones de utils

```
read_csv()
read_csv2()
read_tsv()
read_delim()
read_fwf()
read_table()
read_log()
```

Ejemplos:

```
x <- read_csv("cargadatos/prueba1.txt")
```

```
x <- read_csv("cargadatos/heights.csv ")
```

Especificación de tipos de datos

readr usa heurísticas para detectar el tipo de dato de cada columna

En algunos casos no detecta correctamente el tipo de dato, lo cual podremos hacer manualmente

Ejemplo:

- Descarga el archivo trickydata.csv https://drive.google.com/file/d/1ABfwmOXoMAdGz_c9g_pUjX-93KX9JdOg/view?usp=sharing
- ¿Qué tipo de datos tiene el archivo?
- ¿Encuentras problemas de calidad en los datos?

Especificación de tipos de datos

Carga los datos en R y revisa el formato de los tipos de datos

- Sin especificar el tipo de dato

```
tricky <- read_csv("cargadatos/trickydata.csv")
```

- Especificando el tipo de dato

```
tricky <- read_csv("cargadatos/trickydata.csv",
    col_types = list(
        x = col_double()
    )
)
```

Tipo de variable

Nombre de la variable

Tipos de datos

Type	Function	Expects
Logical	`col_logical()`	T, F, TRUE, FALSE
Integer	`col_integer()`	Integers
Double	`col_double()`	Real numbers, include scientific
Character	`col_character()`	Anything
Dates	`col_date()`	2010-10-20
Date times	`col_datetime()`	2010-10-20 20:15

Sobre las fechas

https://xkcd.com/1179/



Archivo de prueba # 3

- Descarga el archivo weather.csv https://drive.google.com/file/d/1YLmgmoDREMAVcXcFiJEp-6cKqGFBvfNq/view?usp=sharing

- Revisa los tipos de datos de cada columna mediante un editor de texto, identifica las columnas que son
  - Datos de texto
  - Números enteros
  - Números decimales
  - Fechas

- Carga el archivo en R usando readr ¿la heurísitica detectó correctamente las columnas?

Lectura de archivos de Excel

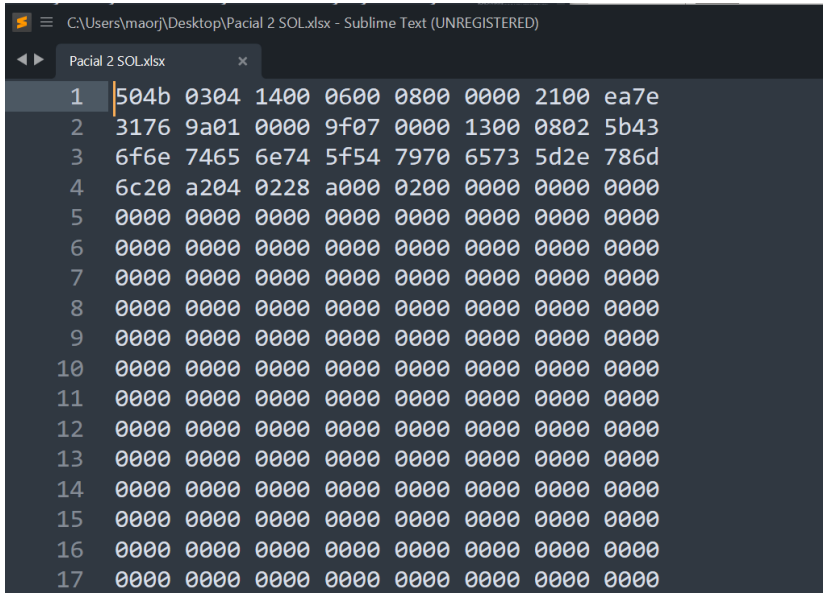
Actividad

- Intenta abrir un archivo de Excel con un editor de texto



Archivos de Excel

Lectura de archivos de Excel



- Un archivo de Excel es diferente al archivo de texto plano
- No se puede abrir con un editor de texto
- Se requiere conocer la lógica de codificación del archivo (o tener una librería que lo sepa)

Instalación de paquetes


```
library(readxls)
```

Habilita la función `read_excel()`

- Permite definir parámetros propios de un archivo de Excel:
  - Número o nombre de hoja
  - Rango de celdas con los datos (p.je C1:E4)
  - Filas o columnas específicas
  - Qué se entiende como un dato nulo (NA)

Instalación de paquetes


```
library(readxls)
```

Habilita la función `read_excel()`

- Permite definir parámetros propios de un archivo de Excel:
  - Número o nombre de hoja
  - Rango de celdas con los datos (p.je C1:E4)
  - Filas o columnas específicas
  - Qué se entiende como un dato nulo (NA)

Gracias por tu asistencia y participación ☺

Contacto

miguela.orjuela@urosario.edu.co

https://www.linkedin.com/in/miguel-orjuela/

https://github.com/maorjuela73