Universidad del Rosario | Escuela de Ciencias e Ingeniería | DEPE

TRANSFORMACIÓN DE DATOS CON R

SÁBADO
4 DE OCTUBRE

10:00 AM A 12:00 PM

En esta sesión de dos horas, nos sumergiremos en el mundo de la transformación de datos utilizando la poderosa biblioteca dplyr en R.

Taller Knuth

MODALIDAD ACCESO REMOTO

NO SE REQUIERE EXPERIENCIA PREVIA EN PROGRAMACIÓN

Sobre el conferencista



Miguel Angel Orjuela Rocha

Ing. de Sistemas y Computación

Skills:

- Desarrollo Fullstack
- Analítica de datos
- Transferencia de conocimiento

Contacto:

miguela.orjuela@urosario.edu.co

https://www.linkedin.com/in/miguel-orjuela/

https://github.com/maorjuela73

Contenido

- Introducción
- Algunos conceptos preliminares
- Operaciones básicas de transformaciones
- Tubos de datos (pipes)

Introducción

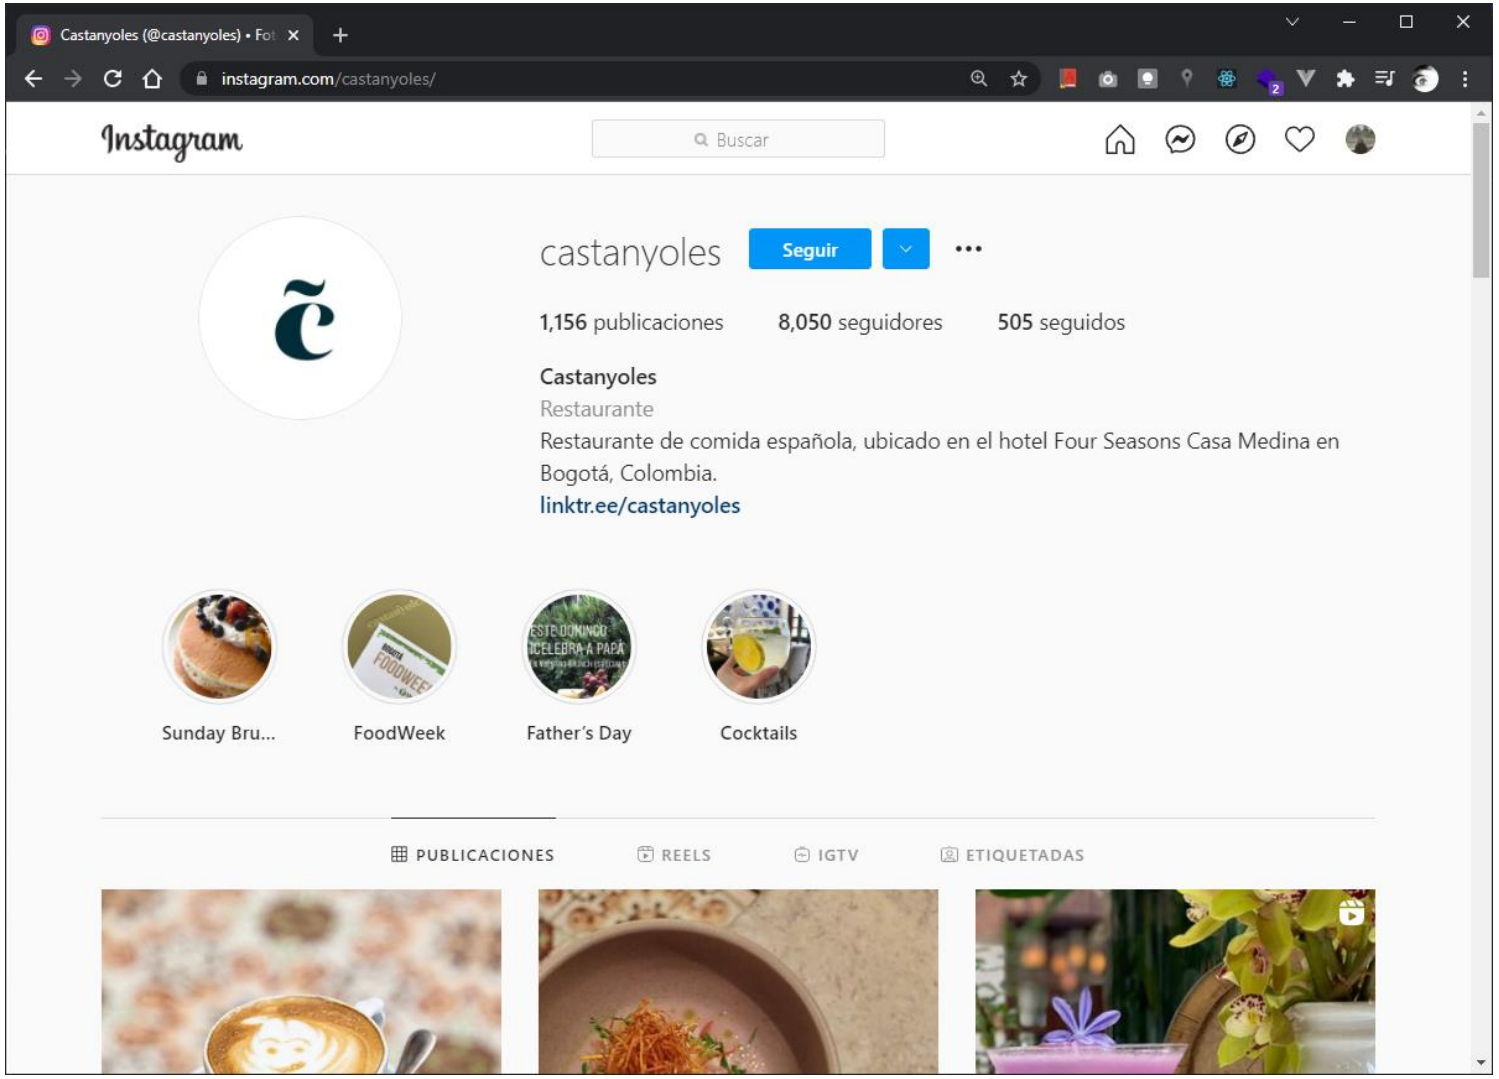
Sobre los datos a analizar

Es raro que vengan exactamente como los necesitamos

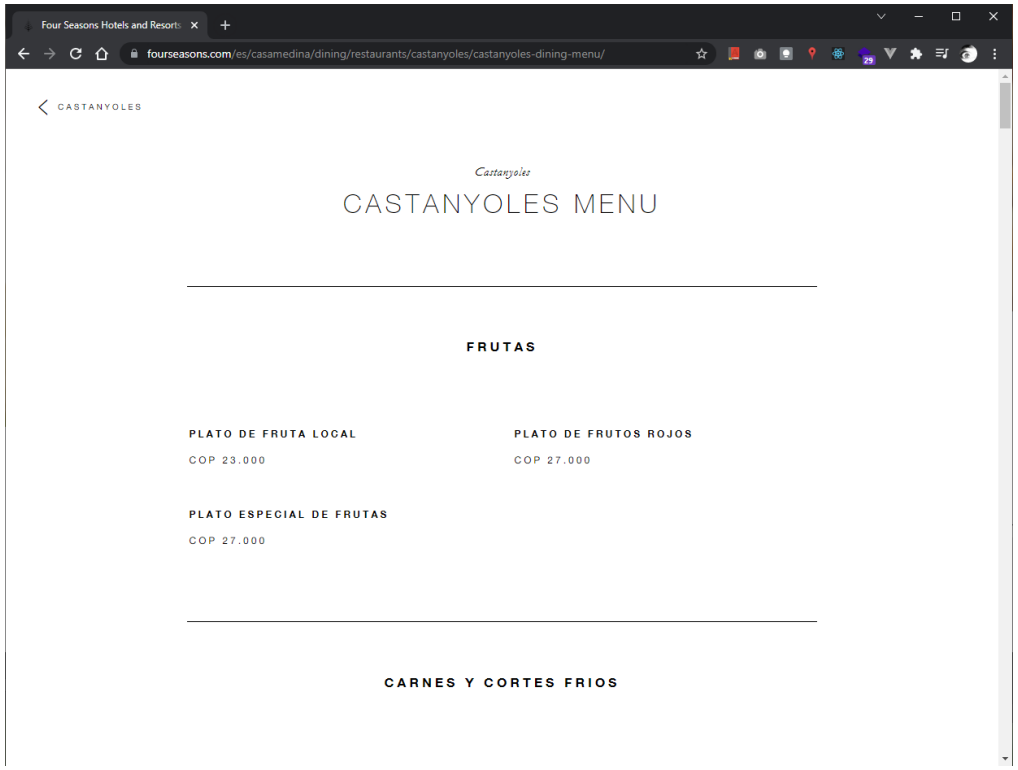
Algunas operaciones que se hacen con frecuencia:

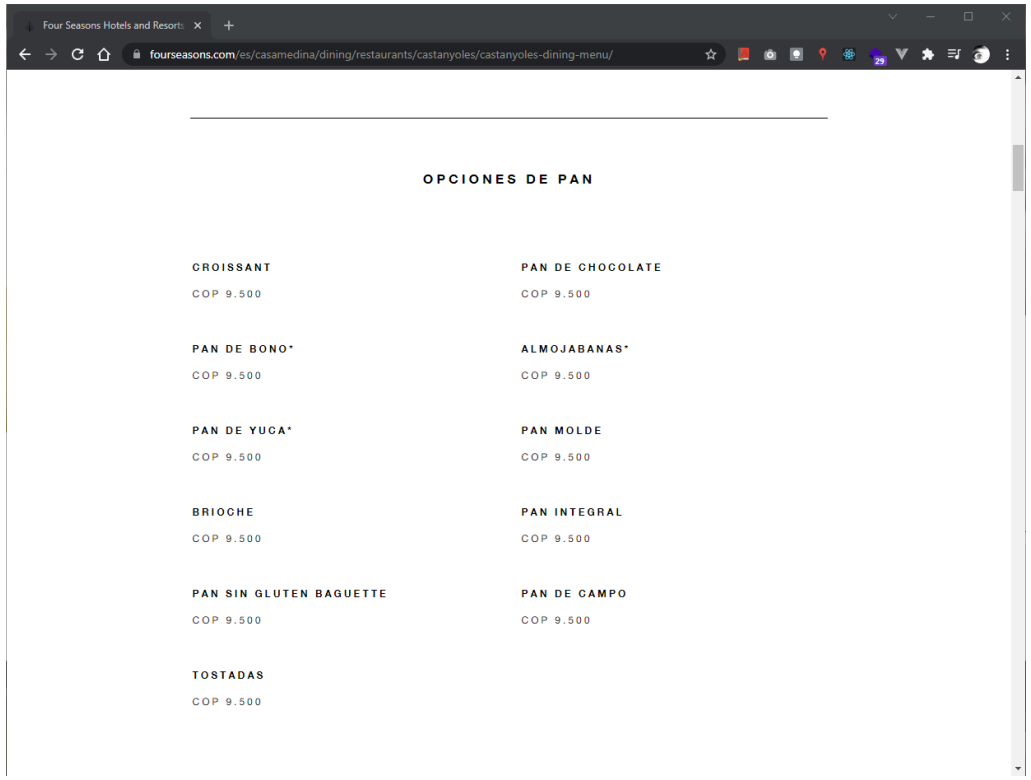
- Cambiarle el nombre a las variables
- Reordenar los datos
- Crear datos a partir de los existentes
- Hacer resumen de los datos

El restaurante



El menú





https://www.fourseasons.com/es/casamedina/dining/restaurants/castanyoles/castanyoles-dining-menu/

Una noche en el restaurante



Los datos que se usan:

- Menú

Nombre del producto, categoría y precio

- Reservas

Nombre de la persona que reserva, datos de contacto

- Consumo en cada reserva

Nombre de la persona que reserva, nombre de cada producto, cantidad

https://docs.google.com/spreadsheets/d/13deCpNrdoTNI2207OGN89oUVsoyv2o-L/edit?usp=share_link&ouid=116142505152764245433&rtpof=true&sd=true

Algunas preguntas

- ¿Cuántas especialidades tiene el restaurante?

ESPECIALIDADES DE CASTAÑYOLES

HUEVOS BENEDICTINOS - TOCINO COP $ 45.000	**HUEVOS BENEDICTINOS – SALMÓN** COP $ 57.000
CALDO DE COSTILLAS COP $ 23.000	**CALENTAO COLOMBIANO** COP $ 38.000
DOS HUEVOS AL GUSTO COP $ 38.000	**PANCAKES** COP $36.000
WAFFLES COP $38.000	**TOSTADAS FRANCESAS** COP $36.000

- ¿Cuánto cuesta en promedio una bebida?

BEBIDAS

AROMÁTICA COP 7.000	**TINTO** COP 7.000
CAFÉ AMERICANO COP 7.000	**ESPRESSO** COP 7.000
SENCILLO COP $7.500	**ESPRESSO DOBLE** COP 10.500
CAPPUCCINO COP 7.500	**MACHIATTO** COP 7.500
CAFÉ LATTE COP 8.500	**CHOCOLATE** COP 8.500
MILO CALIENTE COP 8.500	**MILO FRIO** COP 9.500
MOCCA COP 7.500	**TÉ** COP 7.500
ICE COFFEE COP 10.000	

Algunas preguntas

- ¿Cuánto se recaudó anoche en total en el restaurante?
- ¿Cuánto pagó cada una de las reservas?
- ¿Cuántos diferentes platos ordenó cada reserva?
- ¿Cuál reserva pagó más y cuál pagó menos?
- …

Algunos conceptos preliminares

Programas y paquetes a usar

- R y RStudio



Programas y paquetes a usar

- Librería tidyverse

```
# install.packages("tidyverse")
library(tidyverse)
```

```
> library(tidyverse)
-- Attaching packages --------------- tidyverse 1.3.1 --
v ggplot2 3.3.3     v purrr   0.3.4
v tibble  3.1.1     v dplyr   1.0.5
v tidyr   1.1.3     v stringr 1.4.0
v readr   1.4.0     v forcats 0.5.1
-- Conflicts ------------------ tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
x dplyr::lag()    masks stats::lag()
```

- Un paquete para carga de datos

```
library(readxl)
```

La estructura dataframe


```r
x <- c(25,0,75,200)
y <- c(11,0,53,300)
forma <- c("circulo", "circulo", " cuadrado", "cuadrado")

datos <- data.frame(x,y,forma)

View(datos)
```

x	y	forma
25	11	circulo
0	0	circulo
75	53	cuadrado
200	300	cuadrado

Almacenamiento en Excel

Algunos conceptos preliminares

BEBIDAS

AROMÁTICA

COP 7.000

TINTO

COP 7.000

CAFÉ AMERICANO

COP 7.000

ESPRESSO

COP 7.000

SENCILLO

COP $7.500

ESPRESSO DOBLE

COP 10.500

CAPPUCCINO

COP 7.500

MACHIATTO

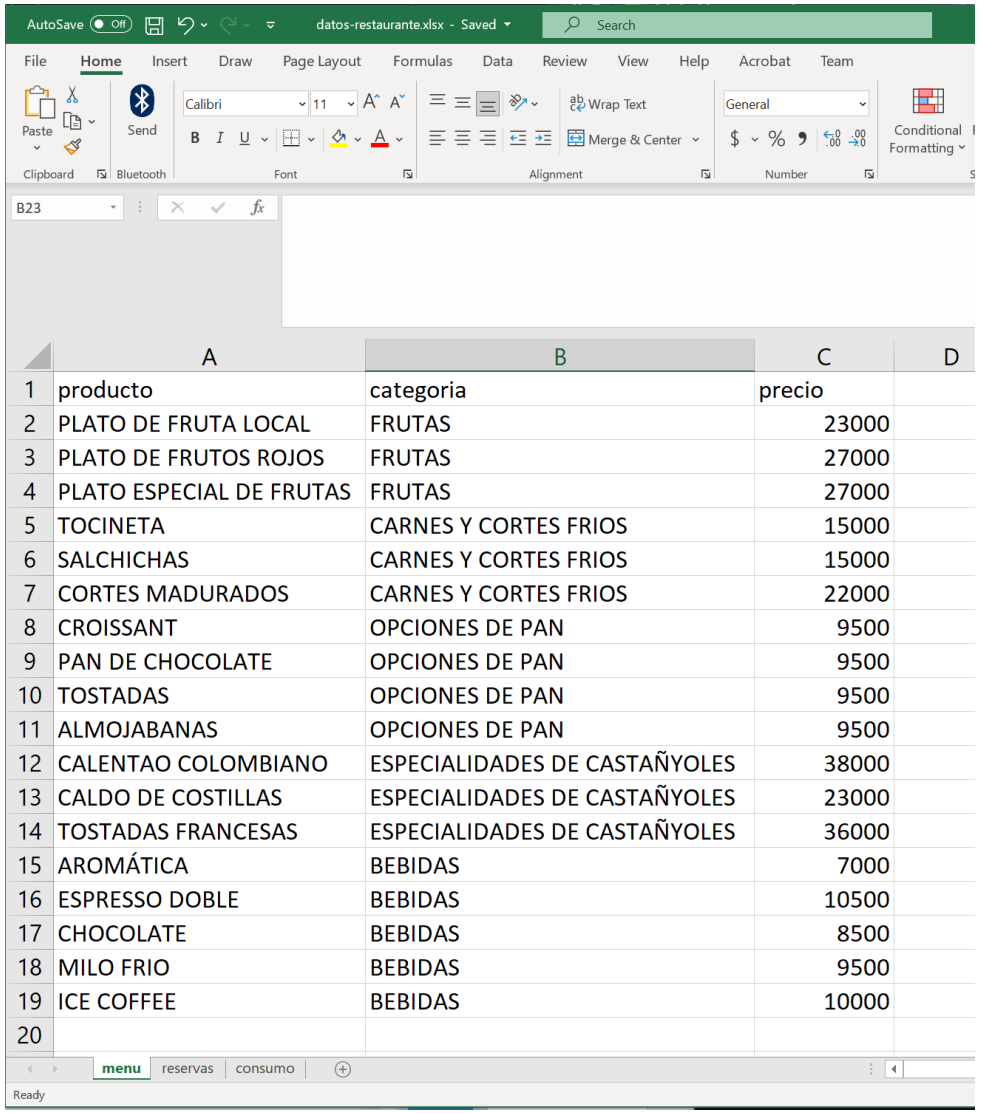
COP 7.500

CAFÉ LATTE

COP 8.500

CHOCOLATE

COP 8.500



	A	B	C	D
1	producto	categoria	precio	
2	PLATO DE FRUTA LOCAL	FRUTAS	23000	
3	PLATO DE FRUTOS ROJOS	FRUTAS	27000	
4	PLATO ESPECIAL DE FRUTAS	FRUTAS	27000	
5	TOCINETA	CARNES Y CORTES FRIOS	15000	
6	SALCHICHAS	CARNES Y CORTES FRIOS	15000	
7	CORTES MADURADOS	CARNES Y CORTES FRIOS	22000	
8	CROISSANT	OPCIONES DE PAN	9500	
9	PAN DE CHOCOLATE	OPCIONES DE PAN	9500	
10	TOSTADAS	OPCIONES DE PAN	9500	
11	ALMOJABANAS	OPCIONES DE PAN	9500	
12	CALENTAO COLOMBIANO	ESPECIALIDADES DE CASTAÑYOLES	38000	
13	CALDO DE COSTILLAS	ESPECIALIDADES DE CASTAÑYOLES	23000	
14	TOSTADAS FRANCESAS	ESPECIALIDADES DE CASTAÑYOLES	36000	
15	AROMÁTICA	BEBIDAS	7000	
16	ESPRESSO DOBLE	BEBIDAS	10500	
17	CHOCOLATE	BEBIDAS	8500	
18	MILO FRIO	BEBIDAS	9500	
19	ICE COFFEE	BEBIDAS	10000	
20				

Carga de archivo de Excel en R

Algunos conceptos preliminares

- Datos

https://docs.google.com/spreadsheets/d/10YPw8v3eD050CuPgjPpk70xhMCq0PsKj/edit?usp=sharing&ouid=116142505152764245433&rtpof=true&sd=true

```
library(tidyverse)
library(readxl)

menu <- read_xlsx("datos-restaurante.xlsx", sheet = "menu")
View(menu)
```

- Los datos cargados quedan en formato dataframe

Algunos tipos de datos

- `int`: números enteros
- `dbl`: Números reales
- `chr`: Vectores de caracteres
- `dttm`: Fechas y horas
- `lgl`: Lógicas (tipos de datos que son CIERTO o FALSO)
- …

Operaciones básicas de transformaciones

Desafíos de manipulación de datos

- Elegir observaciones por sus valores.
- Reordenar las filas.
- Elegir las variables por sus nombres.
- Crear nuevas variables con funciones de variables existentes.
- Contraer muchos valores en un solo resumen.

Funciones principales de dplyr

- Elegir observaciones por sus valores (`filter()`)
- Reordenar las filas (`arrange()`)
- Elegir las variables por sus nombres (`select()`)
- Crear nuevas variables con funciones de variables existentes (`mutate()`)
- Contraer muchos valores en un solo resumen (`summarize()`)

Estructura

- El primer parámetro es un dataframe
- Los siguientes parámetros dicen qué hacer con el dataframe
- Siempre retornan un dataframe
- Nunca modifican el dataframe de entrada

dataframe de ensayo


```r
df <- data.frame(
  color = c("blue", "black", "blue", "blue",
"black"),
  value = 1:5
)
```



df

color	value
blue	1
black	2
blue	3
blue	4
black	5

`filter()`

df

color	value
blue	1
black	2
blue	3
blue	4
black	5



color	value
blue	1
blue	3
blue	4

```
filter(df, color == "blue")
```

- ACTIVIDAD: Filtrar el menú para ver únicamente las bebidas

`filter()`

df

color	value
blue	1
black	2
blue	3
blue	4
black	5



color	value
blue	1
blue	3
blue	4

```
filter(df, value %in% c(1, 4))
```

- ACTIVIDAD: Filtrar el menú para ver únicamente las BEBIDAS y las FRUTAS

`filter()`

df

color	value
blue	1
black	2
blue	3
blue	4
black	5



color	value
blue	1
blue	3
blue	4

```
filter(df, value %in% c(1, 4))
```

- ACTIVIDAD: Filtrar el menú para ver únicamente las BEBIDAS y las FRUTAS

Operadores de comparación

Operador relacional en R	Descripción
>	Mayor que
<	Menor que
>=	Mayor o igual que
<=	Menor o igual que
==	Igual a
!=	Distinto a



```
3 > 5  # TRUE
3 < 5  # FALSE
3 >= 5 # FALSE
3 <= 5 # TRUE
3 == 5 # FALSE
3 != 5 # TRUE
```

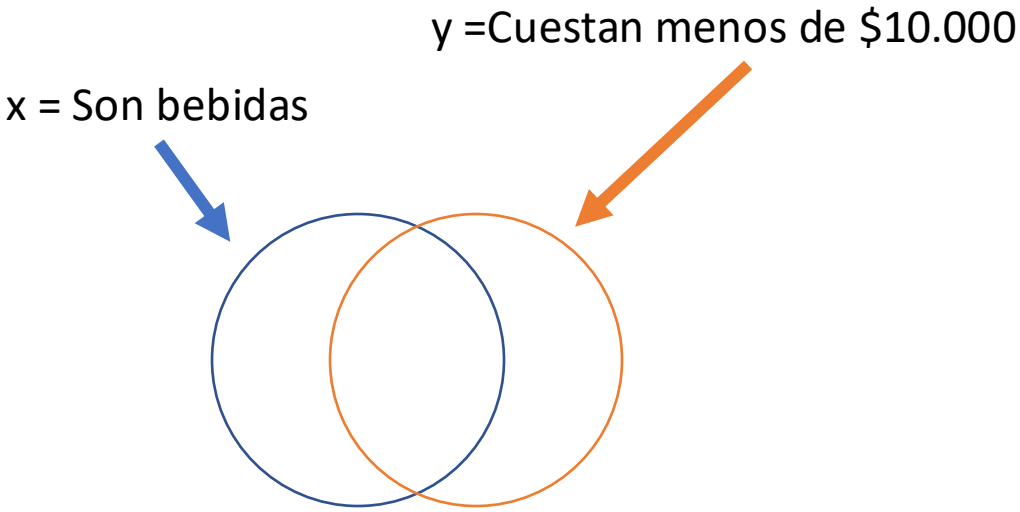
https://r-coder.com/operadores-r/

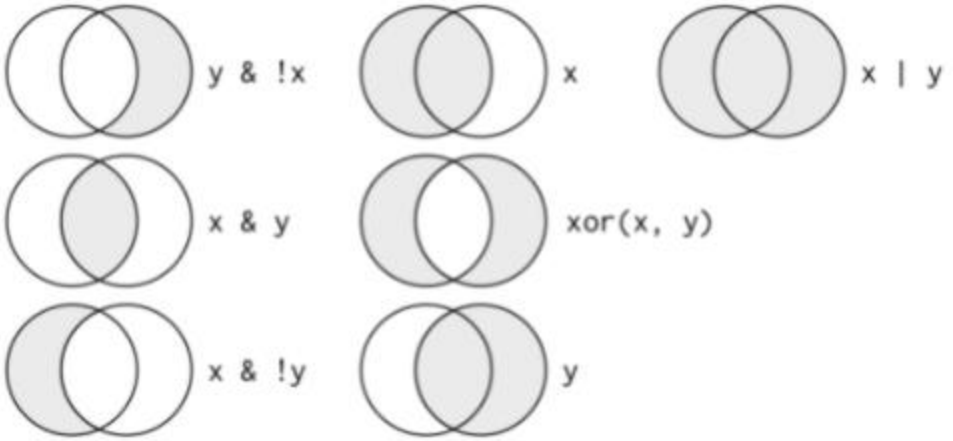
Operadores lógicos

Operador	Comparación	Ejemplo	Resultado
`x | y`	x Ó y es verdadero	`TRUE | FALSE`	`TRUE`
`x & y`	x Y y son verdaderos	`TRUE & FALSE`	`FALSE`
`!x`	x no es verdadero (negación)	`!TRUE`	`FALSE`

https://bookdown.org/jboscomendoza/r-principiantes4/operadores-logicos.html

Condiciones complejas





- ACTIVIDAD: Filtrar el menú para ver únicamente las BEBIDAS o las opciones del menú que cuestan menos de $10.000

`arrange()`

df

color	value
4	1
1	2
5	3
3	4
2	5



color	value
1	2
2	5
3	4
4	1
5	3

```
arrange(df, color)
```

color	value
5	3
4	1
3	4
2	5
1	2

```
arrange(df, desc(color))
```

- ACTIVIDAD: Ordenar el menú por precio

`select()`

df

color	value
blue	1
black	2
blue	3
blue	4
black	5

color
blue
black
blue
blue
black

`select(df, color)`

value
1
2
3
4
5

`select(df, value)`

- ACTIVIDAD: Descarte la columna de categoría de los productos

`mutate()`

df

color	value
blue	1
black	2
blue	3
blue	4
black	5



color	value	double
blue	1	2
black	2	4
blue	3	6
blue	4	8
black	5	10

```
mutate(df, double = 2 * value)
```

- ACTIVIDAD: El restaurante hace una promo. Todos los productos tienen **60%** de descuento. Calcule los precios.

mutate()

df

color	value
blue	1
black	2
blue	3
blue	4
black	5

color	value	double	quadruple
blue	1	2	4
black	2	4	8
blue	3	6	12
blue	4	8	16
black	5	10	20

```
mutate(df,   double = 2 * value,
             quadruple = 2 * double)
```

- ACTIVIDAD: El restaurante hace una promo. Todos los productos tienen **60%** de descuento. Calcule los precios sin IVA en una columna y en otra con el IVA **(19%)**

summarise()


```
consumo <- read_xlsx("datos-restaurante.xlsx", sheet = "consumo")
View(consumo)
```

numero_reserva	nombre	telefono	correo
1	Miguel	3143141414	miguel@correo.com
2	Andrés	3133133131	andres@correo.com
3	Familia Martha	3152151515	martha@correo.com

numero_reserva	producto	cantidad
1	PLATO DE FRUTOS ROJOS	2
1	SALCHICHAS	1
1	PAN DE CHOCOLATE	1
2	CALENTAO COLOMBIANO	1
2	TOSTADAS	1
3	CROISSANT	5
3	AROMÁTICA	1
3	ESPRESSO DOBLE	1
3	CHOCOLATE	1
3	MILO FRIO	1
3	ICE COFFEE	1
3	CALENTAO COLOMBIANO	1
3	TOSTADAS FRANCESAS	1

`summarise()`

df

color	value
blue	1
black	2
blue	3
blue	4
black	5

total
15

```
summarise(df, total = sum(value))
```

- ACTIVIDAD: Calcule el total de productos vendidos en la noche

`summarise()`

df

color	value
blue	1
black	2
blue	3
blue	4
black	5

color	total
blue	8
black	7

```
by_color <- group_by(df, color)
summarise(by_color, total = sum(value))
```

- ACTIVIDAD: Calcule el total de productos vendidos en la noche POR RESERVA

Algunas funciones de resumen


```
by_color <- group_by(df, color)
summarise(by_color, total = sum(value))
```

df

color	value
blue	1
black	2
blue	3
blue	4
black	5

color	total
blue	8
black	7

```
min(x), median(x), max(x),
quantile(x, p)

n(), n_distinct(x), sum(x), mean(x)

sum(x > 10), mean(x > 10)

sd(x), var(x), IQR(x), mad(x)
```

Valores nulos (NA)

- ¿Mary tiene la misma edad de Jaime?
- ¿La edad y el sexo de Jaime es el mismo?

Name	Age	Sex
John	35	M
Mary	NA	F
Jaime	NA	NA

```
NA + 5
10 * NA
10 < NA
10 == NA
NA == NA
is.na(NA)

mean(c(10, 20, NA))
mean(c(10, 20, NA), na.rm = TRUE)
```

Tubos de datos (pipes)

Operador pipe (%>%)

Se lee como “después o luego”

```
menu %>%
  filter(categoria != "FRUTAS") %>%
  select(-producto) %>%
  group_by(categoria) %>%
  summarize(num_productos= n(),
            prom = mean(precio))
```

1. Toma el menú,
2. … después lo filtras para sacar las frutas,
3. … después seleccionas todos menos la columna producto,
4. … después lo agrupas por categoría,
5. … después cuentas y sacas promedios

Gracias por tu asistencia y participación ☺

Contacto

miguela.orjuela@urosario.edu.co
https://www.linkedin.com/in/miguel-orjuela/
https://github.com/maorjuela73

Links de interés

- *https://bookdown.org/rdpeng/rprogdatascience/*
- *https://www.rstudio.com/resources/cheatsheets/*