Universidad del Rosario | Escuela de Ciencias e Ingeniería | DEPE

# ORDENAMIENTO DE DATOS PARA ANÁLISIS EN R

SÁBADO
**25 DE OCTUBRE**

**10:00 AM A 12:00 PM**

Este taller ilustra el concepto de base de datos ordenada mediante la realización de actividades de transformación de una base de datos.

## Taller Knuth

**MODALIDAD ACCESO REMOTO**

NO SE REQUIERE EXPERIENCIA PREVIA EN PROGRAMACIÓN

## Sobre el conferencista



# Miguel Angel Orjuela Rocha

Ing. de Sistemas y Computación

**Skills:**

- Desarrollo Fullstack
- Analítica de datos
- Transferencia de conocimiento

**Contacto:**


miguela.orjuela@urosario.edu.co

https://www.linkedin.com/in/miguel-orjuela/

https://github.com/maorjuela73

# Contenido

- ¿Qué es ordenar los datos?
- Herramientas a usar
- Reglas para ordenar un dataset
- Operaciones principales de tidyr

# ¿Qué es ordenar los datos?

# Representación de los datos

**¿Qué es ordenar los datos?**

Existen varias formas de representar la misma información

| | Prueba A | Prueba B |
|---|---|---|
| Manuel Martinez | - | 2 |
| Jhon Salcedo | 16 | 11 |
| Carlos Zarate | 3 | 1 |

| Persona | Prueba | Resultado |
|---|---|---|
| Manuel Martinez | A | - |
| Jhon Salcedo | A | 16 |
| Carlos Zarate | A | 3 |
| Manuel Martinez | B | 2 |
| Jhon Salcedo | B | 11 |
| Carlos Zarate | B | 1 |

| | Manuel Martinez | Jhon Salcedo | Carlos Zarate |
|---|---|---|---|
| Prueba A | - | 16 | 3 |
| Prueba B | 2 | 11 | 1 |

# Semántica

**¿Qué es ordenar los datos?**

**Dataset**: Es una colección de valores. Atributos medidos en unidades observacionales.

División según el tipo de atributo:

- Cualitativos (strings)
- Cuantitativos (números)

Cada valor en un dataset pertenece a una **variable** y a una **observación**

- **Variable**: Todos los valores que miden el mismo atributo en todas las unidades observacionales
- **Observación**: Todos los valores que toman los atributos, medidos en una unidad observacional

# Semántica

**¿Qué es ordenar los datos?**

¿Qué son variables y qué son observaciones en este dataset?

| | Prueba A | Prueba B |
|---|---|---|
| Manuel Martinez | - | 2 |
| Jhon Salcedo | 16 | 11 |
| Carlos Zarate | 3 | 1 |

# Una transformación de ordenamiento

**¿Qué es ordenar los datos?**

| | Prueba A | Prueba B |
|---|---|---|
| Manuel Martinez | - | 2 |
| Jhon Salcedo | 16 | 11 |
| Carlos Zarate | 3 | 1 |



| Persona | Prueba | Resultado |
|---|---|---|
| Manuel Martinez | A | - |
| Jhon Salcedo | A | 16 |
| Carlos Zarate | A | 3 |
| Manuel Martinez | B | 2 |
| Jhon Salcedo | B | 11 |
| Carlos Zarate | B | 1 |

# Una transformación de ordenamiento

**¿Qué es ordenar los datos?**

| | Prueba A | Prueba B |
|---|---|---|
| Manuel Martinez | - | 2 |
| Jhon Salcedo | 16 | 11 |
| Carlos Zarate | 3 | 1 |



| Persona | Prueba | Resultado |
|---|---|---|
| Manuel Martinez | A | - |
| Jhon Salcedo | A | 16 |
| Carlos Zarate | A | 3 |
| Manuel Martinez | B | 2 |
| Jhon Salcedo | B | 11 |
| Carlos Zarate | B | 1 |

# Una transformación de ordenamiento

**¿Qué es ordenar los datos?**

| | Prueba A | Prueba B |
|---|---|---|
| Manuel Martinez | - | 2 |
| Jhon Salcedo | 16 | 11 |
| Carlos Zarate | 3 | 1 |



| Persona | Prueba | Resultado |
|---|---|---|
| Manuel Martinez | A | - |
| Jhon Salcedo | A | 16 |
| Carlos Zarate | A | 3 |
| Manuel Martinez | B | 2 |
| Jhon Salcedo | B | 11 |
| Carlos Zarate | B | 1 |

# Una transformación de ordenamiento

**¿Qué es ordenar los datos?**

| | Prueba A | Prueba B |
|---|---|---|
| Manuel Martinez | - | 2 |
| Jhon Salcedo | 16 | 11 |
| Carlos Zarate | 3 | 1 |



| Persona | Prueba | Resultado |
|---|---|---|
| Manuel Martinez | A | - |
| Jhon Salcedo | A | 16 |
| Carlos Zarate | A | 3 |
| Manuel Martinez | B | 2 |
| Jhon Salcedo | B | 11 |
| Carlos Zarate | B | 1 |

# Una transformación de ordenamiento

**¿Qué es ordenar los datos?**

| | Prueba A | Prueba B |
|---|---|---|
| Manuel Martinez | - | 2 |
| Jhon Salcedo | 16 | 11 |
| Carlos Zarate | 3 | 1 |



| Persona | Prueba | Resultado |
|---|---|---|
| Manuel Martinez | A | - |
| Jhon Salcedo | A | 16 |
| Carlos Zarate | A | 3 |
| Manuel Martinez | B | 2 |
| Jhon Salcedo | B | 11 |
| Carlos Zarate | B | 1 |

# Una transformación de ordenamiento

**¿Qué es ordenar los datos?**

| | Prueba A | Prueba B |
|---|---|---|
| Manuel Martinez | - | 2 |
| Jhon Salcedo | 16 | 11 |
| Carlos Zarate | 3 | 1 |



| Persona | Prueba | Resultado |
|---|---|---|
| Manuel Martinez | A | - |
| Jhon Salcedo | A | 16 |
| Carlos Zarate | A | 3 |
| Manuel Martinez | B | 2 |
| Jhon Salcedo | B | 11 |
| Carlos Zarate | B | 1 |

# Una transformación de ordenamiento

**¿Qué es ordenar los datos?**

| | Prueba A | Prueba B |
|---|---|---|
| Manuel Martinez | - | 2 |
| Jhon Salcedo | 16 | 11 |
| Carlos Zarate | 3 | 1 |



| Persona | Prueba | Resultado |
|---|---|---|
| Manuel Martinez | A | - |
| Jhon Salcedo | A | 16 |
| Carlos Zarate | A | 3 |
| Manuel Martinez | B | 2 |
| Jhon Salcedo | B | 11 |
| Carlos Zarate | B | 1 |

# Herramientas a usar

# RStudio Cloud



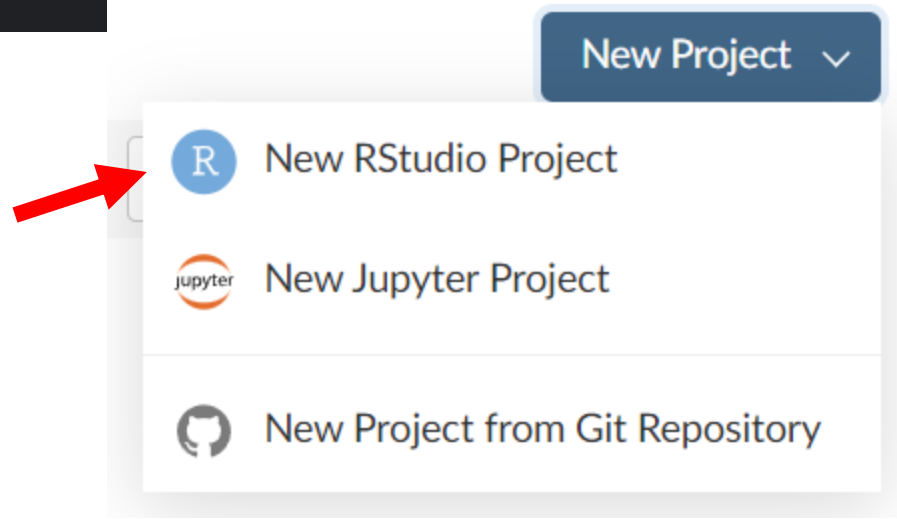
- Servicio web que permite ejecutar R en la nube (servidores de RStudio)

https://rstudio.cloud ▾ Traducir esta página

RStudio Cloud

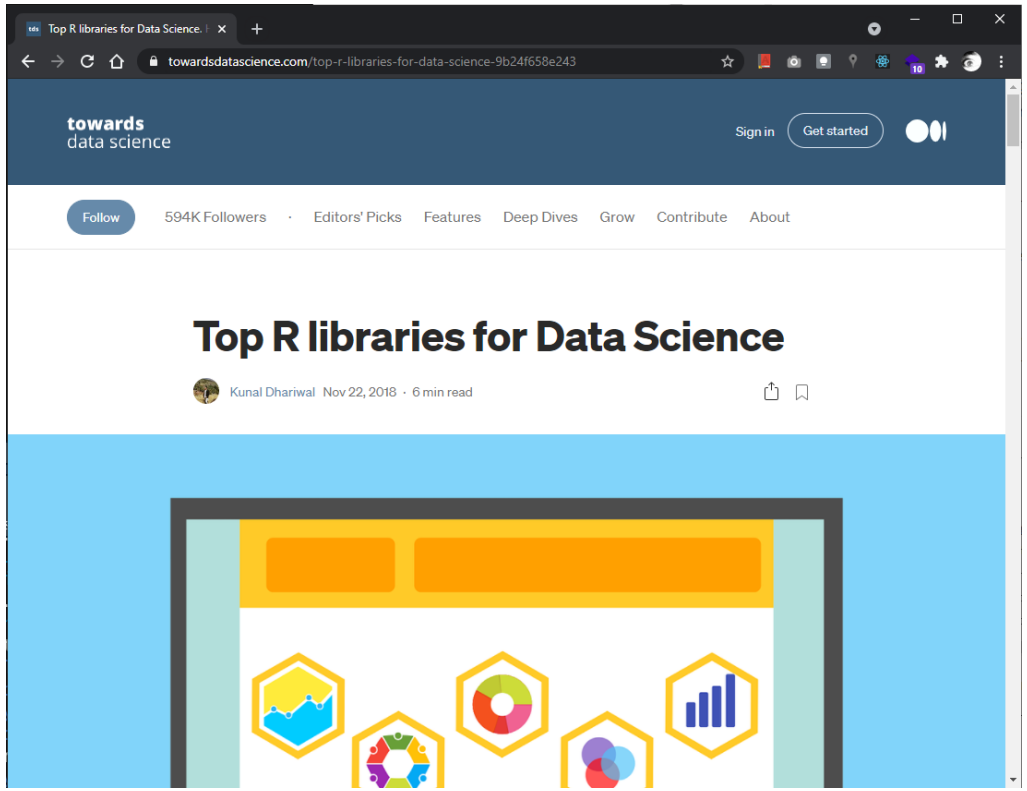
**RStudio Cloud** is a lightweight, cloud-based solution that allows anyone to do, share, teach and learn data science online. ... There is nothing to configure and ...

- Se inicia sesión y se crea un nuevo proyecto



# Instalación de paquetes

Herramientas a emplear




```r
# Se necesitan instalar una vez
# por computador

install.packages("nombrepaquete")

# pero hay que cargarlo cada vez
# que se inicia R

library(nombredelpaquete)
```

# Instalación de paquetes

Herramientas a emplear

```
# librerías importantes

library(readr)

library(tidyr)

library(dplyr)

library(ggplot2)
```



# Programas y paquetes a usar



- Librería tidyverse

```
# install.packages("tidyverse")
library(tidyverse)
```

```
> library(tidyverse)
-- Attaching packages --------------- tidyverse 1.3.1 --
v ggplot2 3.3.3     v purrr   0.3.4
v tibble  3.1.1     v dplyr   1.0.5
v tidyr   1.1.3     v stringr 1.4.0
v readr   1.4.0     v forcats 0.5.1
-- Conflicts ------------------ tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
x dplyr::lag()    masks stats::lag()
```

# Reglas para ordenar un dataset

# Características de los datos ordenados

**Reglas para ordenar un dataset**

- Cada variable forma una columna
- Cada observación forma una fila
- Cada tipo de unidad observacional forma una tabla

| | Prueba A | Prueba B |
|---|---|---|
| Manuel Martinez | - | 2 |
| Jhon Salcedo | 16 | 11 |
| Carlos Zarate | 3 | 1 |



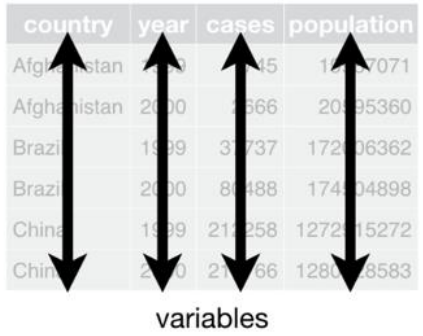
| Persona | Prueba | Resultado |
|---|---|---|
| Manuel Martinez | A | - |
| Jhon Salcedo | A | 16 |
| Carlos Zarate | A | 3 |
| Manuel Martinez | B | 2 |
| Jhon Salcedo | B | 11 |
| Carlos Zarate | B | 1 |



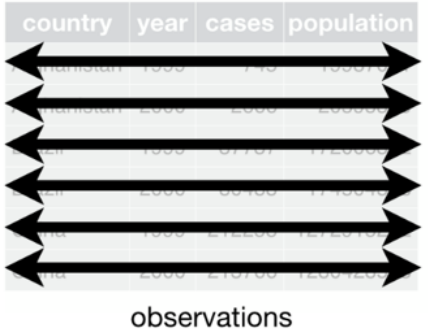
# Reglas para ordenar datos

**Reglas para ordenar un dataset**

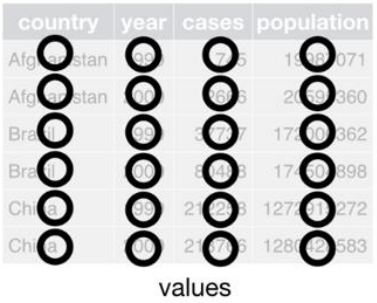
- Cada variable forma una columna




- Cada observación forma una fila




- Cada tipo de unidad observacional forma una tabla



# Problemas más frecuentes

**Reglas para ordenar un dataset**

- Los encabezados de las columnas son valores
- Hay múltiples variables en una columna
- Los valores están almacenados en filas y columnas
- Varios tipos de unidades observacionales en la misma tabla
- Una única unidad observacional está almacenada en tablas múltiples

# Algunos ejemplos

**Reglas para ordenar un dataset**

Cargar la librería tidyverse

```
library(tidyverse)
```

```
table1
table2
table3
table4a
table4b
```

- Los encabezados de las columnas son valores
- Hay múltiples variables en una columna
- Los valores están almacenados en filas y columnas
- Varios tipos de unidades observacionales en la misma tabla
- Una única unidad observacional está almacenada en tablas múltiples

# Ventajas

**Reglas para ordenar un dataset**

- Es una forma consistente de almacenar los datos
- La mayoría de funciones de R trabajan con vectores de datos

Ejemplo: Cálculo de información derivada

```
# Casos por cada 10,000 habitantes
table1 %>%
  mutate(rate = cases / population * 10000)

# Casos totales por aNo
table1 %>%
  count(year, wt = cases)
```

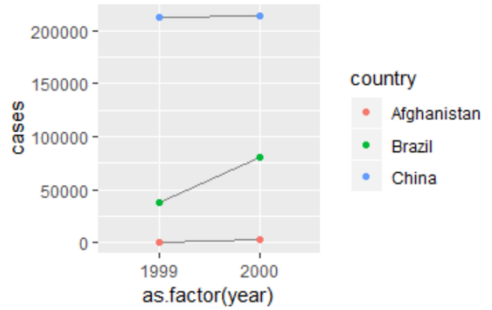
# Ventajas

**Reglas para ordenar un dataset**

- Compatibilidad extra con otros paquetes del tidyverse

Ejemplo: Gráfico de los datos

```
# Visualizar cambios a través del tiempo
library(ggplot2)
ggplot(table1, aes(year, cases)) +
  geom_line(aes(group = country), colour = "grey50") +
  geom_point(aes(colour = country))
```



# Operaciones principales de tidyr


Funciones de Tidyr
Pivoteo
pivot_longer(): Nuevo en tidyr 1.0.0, reemplaza `spread()`. Convierte datos de un formato ancho a largo.
pivot_wider(): Nuevo en tidyr 1.0.0, reemplaza `gather()`. Transforma datos de un formato largo a ancho.
Rectangling
unnest_longer(): Expande listas en columnas de una forma más larga.
unnest_wider(): Expande listas en columnas de una forma más ancha.
hoist(): Extrae elementos de listas anidadas sin expandir todo en filas o columnas.
Anidamiento
nest(): Crea un marco de datos anidado agrupando variables seleccionadas.
unnest(): Desanida un marco de datos anidado en filas de un marco de datos principal.
División y combinación de columnas de caracteres
separate_wider_delim(): Separa una columna en varias columnas usando un delimitador específico.
separate_wider_position(): Separa una columna en varias basándose en posiciones fijas de los caracteres.
separate_wider_regex(): Utiliza expresiones regulares para dividir una columna en múltiples columnas.
unite(): Combina varias columnas en una sola, utilizando un delimitador específico.
Manejo de valores faltantes
complete(): Hace explícitos los valores faltantes implícitos generando combinaciones faltantes de datos.
drop_na(): Elimina filas que contienen valores faltantes.
fill(): Reemplaza los valores faltantes con el valor siguiente o anterior dentro de una columna.
replace_na(): Reemplaza los valores faltantes con un valor conocido especificado.

# Cuatro operaciones de ordenamiento

**Operaciones principales de tidyr**

- Separate
- Unite
- Gather
- Spread

# table5

**Operaciones principales de tidyr**

| country | century | year | rate |
|---|---|---|---|
| Afghanistan | 19 | 99 | 745/19987071 |
| Afghanistan | 20 | 00 | 2666/20595360 |
| Brazil | 19 | 99 | 37737/172006362 |
| Brazil | 20 | 00 | 80488/174504898 |
| China | 19 | 99 | 212258/1272915272 |
| China | 20 | 00 | 213766/1280428583 |

# Separate



table5

| country | year | rate |
|---|---|---|
| Afghanistan | 1999 | **745** / 19987071 |
| Afghanistan | 2000 | **2666** / 20595360 |
| Brazil | 1999 | **37737** / 172006362 |
| Brazil | 2000 | **80488** / 174504898 |
| China | 1999 | **212258** / 1272915272 |
| China | 2000 | **213766** / 1280428583 |



| country | year | cases | population |
|---|---|---|---|
| Afghanistan | 1999 | **745** | 19987071 |
| Afghanistan | 2000 | **2666** | 20595360 |
| Brazil | 1999 | **37737** | 172006362 |
| Brazil | 2000 | **80488** | 174504898 |
| China | 1999 | **212258** | 1272915272 |
| China | 2000 | **213766** | 1280428583 |

```
table5 %>%
  separate(rate, into = c("cases", "population"), sep = "/")
```

# Unite





| country | year | rate |
|---|---|---|
| Afghanistan | 1999 | 745 / 19987071 |
| Afghanistan | 2000 | 2666 / 20595360 |
| Brazil | 1999 | 37737 / 172006362 |
| Brazil | 2000 | 80488 / 174504898 |
| China | 1999 | 212258 / 1272915272 |
| China | 2000 | 213766 / 1280428583 |

table5

| country | century | year | rate |
|---|---|---|---|
| Afghanistan | 19 | 99 | 745 / 19987071 |
| Afghanistan | 20 | 0 | 2666 / 20595360 |
| Brazil | 19 | 99 | 37737 / 172006362 |
| Brazil | 20 | 0 | 80488 / 174504898 |
| China | 19 | 99 | 212258 / 1272915272 |
| China | 20 | 0 | 213766 / 1280428583 |

```
table5 %>%
  unite(new, century, year)
```

# table4a



| country | 1999 | 2000 |
|---|---|---|
| Afghanistan | 745 | 2666 |
| Brazil | 37737 | 80488 |
| China | 212258 | 213766 |

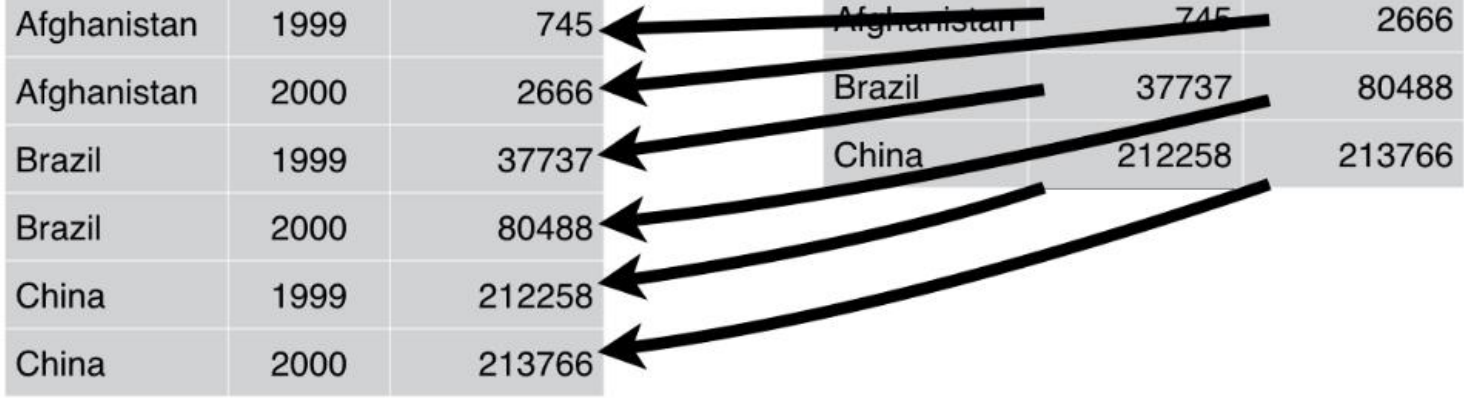
# gather



| country | year | cases |
|---|---|---|
| Afghanistan | 1999 | 745 |
| Afghanistan | 2000 | 2666 |
| Brazil | 1999 | 37737 |
| Brazil | 2000 | 80488 |
| China | 1999 | 212258 |
| China | 2000 | 213766 |

table4a

| country | 1999 | 2000 |
|---|---|---|
| Afghanistan | 745 | 2666 |
| Brazil | 37737 | 80488 |
| China | 212258 | 213766 |



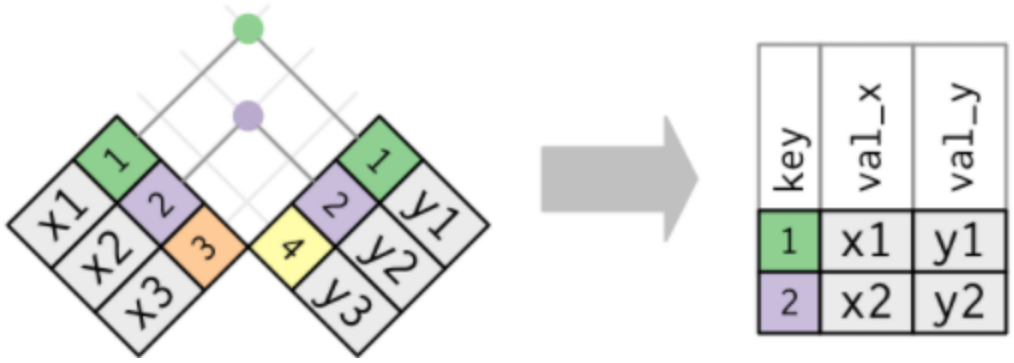
```
table4a %>%
  gather(`1999`, `2000`, key = "year", value = "cases")
```

# gather

Operaciones principales de tidyr

```
tidy4a <- table4a %>%
  gather(`1999`, `2000`, key = "year", value = "cases")

tidy4b <- table4b %>%
  gather(`1999`, `2000`, key = "year", value = "population")
```




```
left_join(tidy4a, tidy4b)
```

# table2

**Operaciones principales de tidyr**

| country | year | type | count |
|---|---|---|---|
| Afghanistan | 1999 | cases | 745 |
| Afghanistan | 1999 | population | 19987071 |
| Afghanistan | 2000 | cases | 2666 |
| Afghanistan | 2000 | population | 20595360 |
| Brazil | 1999 | cases | 37737 |
| Brazil | 1999 | population | 172006362 |
| Brazil | 2000 | cases | 80488 |
| Brazil | 2000 | population | 174504898 |
| China | 1999 | cases | 212258 |
| China | 1999 | population | 1272915272 |
| China | 2000 | cases | 213766 |
| China | 2000 | population | 1280428583 |

# Separate

Operaciones principales de tidyr

| country | year | key | value |
|---|---|---|---|
| Afghanistan | 1999 | cases | 745 |
| Afghanistan | 1999 | population | 19987071 |
| Afghanistan | 2000 | cases | 2666 |
| Afghanistan | 2000 | population | 20595360 |
| Brazil | 1999 | cases | 37737 |
| Brazil | 1999 | population | 172006362 |
| Brazil | 2000 | cases | 80488 |
| Brazil | 2000 | population | 174504898 |
| China | 1999 | cases | 212258 |
| China | 1999 | population | 1272915272 |
| China | 2000 | cases | 213766 |
| China | 2000 | population | 1280428583 |



| country | year | cases | population |
|---|---|---|---|
| Afghanistan | 1999 | 745 | 19987071 |
| Afghanistan | 2000 | 2666 | 20595360 |
| Brazil | 1999 | 37737 | 172006362 |
| Brazil | 2000 | 80488 | 174504898 |
| China | 1999 | 212258 | 1272915272 |
| China | 2000 | 213766 | 1280428583 |

```
table2 %>%
    spread(key = type, value = count)
```

# Plataforma de Datos Abiertos del Colombia

**Práctica**



# Índice de precios de insumos agrícolas

Práctica

- Resumen: Índice que refleja el comportamiento de los precios de productos utilizados en la actividad agrícola a nivel nacional.
  - Productos Cubiertos:
  - Fertilizantes:Simples (e.g., nitrógeno, potasio)Compuestos (mezclas de nutrientes)
  - Plaguicidas:HerbicidasFungicidasInsecticidas
  - Otros Insumos:Coadyuvantes (mejoradores de la efectividad de productos)Reguladores FisiológicosMolusquicidas (control de plagas como caracoles y babosas)

- Propósito del Índice:
  - Toma de Decisiones: Proveer información para apoyar decisiones estratégicas en el sector agrícola.
  - Monitorear el comportamiento de precios en las diferentes etapas de la producción agrícola.

https://www.datos.gov.co/Agricultura-y-Desarrollo-Rural/-ndice-de-precios-de-insumos-agr-colas/gwbi-fnzs/about_data

# Problemas del dataset

Práctica

- Descarga el Dataset:

https://drive.google.com/file/d/1rLdD3yafd4RQBMpb4U2REsZgp8Bg91F9/view?usp=sharing

- ¿Qué problemas puedes identificar en este conjunto de datos que dificultan su análisis?

# Actividad práctica

**Paso 1**: Imagina que necesitas preparar este dataset para un análisis de tendencias por categoría de producto. Usa las funciones de tidyr para:

- Hacerlo más largo o más ancho según sea necesario.
- Limpiar los valores nulos.
- Separar columnas si es necesario.
- Todo esto debe llevarte a un formato que te permita fácilmente visualizar tendencias."

# Actividad práctica

**Paso 2**: Ahora que hemos reorganizado los datos, podemos limpiar cualquier fila que tenga valores nulos en la columna Asdf

```
# Eliminar filas con valores nulos en la
columna 'Indice'
datos_limpios <- datos_largos %>%
  drop_na(Asdf)
```

# Resultado esperado

**Producto:** contiene el tipo de producto (fertilizantes, plaguicidas, etc.).

**Indice:** contiene el valor del índice correspondiente a cada producto y fecha.

| Fecha | Producto | Indice |
|---|---|---|
| 12/2018 | Total_Fertilizantes | 90.36 |
| 12/2018 | Total_Plaguicidas | 91.24 |
| 12/2018 | Total_Herbicidas | 93.56 |
| ... | ... | ... |

# Reflexiona sobre tus decisiones

- Formato de los Datos:
  - ¿Qué formato (ancho o largo) encontraste más adecuado para este tipo de análisis? ¿Por qué?
  - ¿Qué tan fácil fue trabajar con los datos una vez que los transformaste?
  - ¿Qué problemas surgieron durante la manipulación de los datos?
- Valores Nulos:
  - ¿Hubo algún cambio en el análisis que hubieras hecho si decidieras no eliminar los valores nulos?
  - ¿Cómo afectó la decisión de manejar los valores nulos en el resultado final?
- Separación o Unión de Columnas:
  - Si separaste o uniste columnas, ¿por qué lo hiciste? ¿Cómo mejoró esto la comprensión de los datos?
  - ¿Qué beneficios encontraste al transformar o unificar ciertas columnas en una sola?

# Otras alternativas

- Métodos Alternativos:
  - ¿Qué métodos alternativos podrías haber considerado para reorganizar los datos? Por ejemplo, ¿sería mejor mantener el formato original para algunos productos específicos?
  - ¿Crees que habría algún valor en aplicar una estrategia diferente de limpieza o reorganización de los datos?
- Visualización de Tendencias:
  - ¿Qué transformaciones te permitieron visualizar mejor las tendencias de los datos?
  - ¿Hay alguna otra manera en que podrías haber visualizado los datos más eficazmente?

# Gracias por tu asistencia y participación ☺

**Contacto**

miguela.orjuela@urosario.edu.co
https://www.linkedin.com/in/miguel-orjuela/
https://github.com/maorjuela73

**Links de interés**

- *https://bookdown.org/rdpeng/rprogdatascience/*
- *https://www.rstudio.com/resources/cheatsheets/*